

MEMORIA TRABAJO FINAL DE GRADO

Título:

Prelocalización anatómica externa en entornos hospitalarios mediante estimación de pose humana y visión artificial

Estudiante: Marta López Navio

Tutor/a: Ramón Alberto Mollineda Cardenas

Curso 2025/2026

Fecha de presentación: 12 de junio de 2026

Agradecimientos:

Quisiera agradecer, en primer lugar, a mi tutor del Trabajo Final de Grado por su orientación, seguimiento y ayuda durante el desarrollo de este proyecto. También quiero agradecer al equipo de CIRTESU por facilitarme el espacio, los recursos y el apoyo necesario para realizar las pruebas experimentales y avanzar en la integración del sistema robótico.

Agradezco especialmente a mis compañeros y compañeras de CIRTESU por su ayuda durante el desarrollo del trabajo, tanto en la resolución de problemas técnicos como en las pruebas realizadas. En particular, quiero dar las gracias a mi compañera Camila Vega por su colaboración durante las pruebas del sistema y por aparecer en muchas de las imágenes utilizadas para documentar el funcionamiento del proyecto.

Finalmente, quiero agradecer a mi familia y personas cercanas su apoyo durante todo el proceso de elaboración de este Trabajo Final de Grado.

Palabras clave:

Robótica asistencial; visión artificial; estimación de pose humana; RTMPose; prelocalización anatómica externa; landmarks anatómicos; estimación de profundidad; Depth Anything 3; Intel RealSense; ROS2; robot móvil.

Nota sobre figuras y tablas: salvo indicación contraria, todas las figuras, tablas, capturas e imágenes incluidas en esta memoria son de elaboración propia.

CASTELLÓN, a 12 de junio de 2026

Todos los derechos reservados

TABLA DE CONTENIDOS

	Glosario de términos y abreviaturas	7
1	Introducción	11
1.1	Contexto del proyecto	11
1.2	Motivación	12
1.3	Planteamiento del problema	13
1.4	Objetivos	14
1.4.1	Objetivo general	14
1.4.2	Objetivos específicos	14
1.5	Alcance y limitaciones del proyecto	15
1.6	Planificación del trabajo	15
1.6.1	Fases de desarrollo	15
1.6.2	Desviaciones respecto a la planificación inicial	16
1.6.3	Diagrama de Gantt	17
1.7	Estimación de costes	18
1.8	Estructura del documento	20
2	Marco teórico y estado del arte	21
2.1	Robótica asistencial en entornos hospitalarios	21
2.2	Prelocalización anatómica externa	21
2.3	Estimación de pose humana	22
2.3.1	Concepto de keypoints y skeleton corporal	22
2.3.2	Problemas de oclusión y ropa hospitalaria	23

2.4	Modelos de estimación de pose	23
2.4.1	YOLO-Pose	23
2.4.2	RTMPose	23
2.4.3	ViTPose	25
2.4.4	OpenPose	25
2.5	Selección del modelo de pose para el proyecto	25
2.6	Estimación de profundidad	26
2.6.1	Sensores RGB-D: Intel RealSense	26
2.6.2	Estimación monocular de profundidad	26
2.6.3	Depth Anything 3	27
2.7	ROS2 como middleware robótico	28
2.8	Comunicación entre PC, Android y robot móvil	28
2.9	Conclusiones del estado del arte	29
3	Análisis y diseño del sistema	31
3.1	Requisitos del sistema	31
3.1.1	Requisitos funcionales	31
3.1.2	Requisitos no funcionales	32
3.2	Arquitectura general del sistema	33
3.3	Diseño del módulo de percepción	34
3.3.1	Captura de imagen	34
3.3.2	Detección de pose humana	34
3.3.3	Obtención de landmarks anatómicos externos	35
3.4	Definición de landmarks anatómicos	36
3.4.1	Base cervical	36
3.4.2	Región tiroidea aproximada	37
3.4.3	Centro pélvico	37
3.4.4	Región prostática aproximada	38
3.5	Validación de orientación del paciente	38
3.5.1	Detección de frontalidad	38
3.5.2	Condiciones para permitir la medición	39
3.6	Diseño del módulo de profundidad	40
3.6.1	Lectura de profundidad en landmarks	40
3.6.2	Suavizado temporal	41
3.6.3	Clasificación de distancia	41
3.6.4	Criterios para la elección de umbrales de distancia	42
3.7	Diseño del módulo de decisión	43
3.7.1	Acciones de acercamiento y alejamiento	43
3.7.2	Centrado horizontal del robot	43
3.7.3	Combinación de acciones	44
3.7.4	Bloqueo de posición alcanzada	44
3.8	Diseño de la comunicación	45
3.8.1	Publicación de información en ROS2	45
3.8.2	Puente ROS2–Android	45
3.8.3	Comunicación Android–MiniCERNBot	45
3.9	Diseño de interfaces y visualización	46

4	Implementación	47
4.1	Hardware utilizado	48
4.1.1	Cámara Intel RealSense	48
4.1.2	Equipo de procesamiento	48
4.1.3	Dispositivo Android	49
4.1.4	MiniCERNBot	49
4.2	Entornos de software	50
4.2.1	Entorno OpenMMLab	50
4.2.2	Entorno Depth Anything 3	50
4.2.3	Entorno ROS2 Humble	50
4.3	Implementación del módulo de pose	50
4.3.1	Integración de RTMPose	50
4.3.2	Motor de landmarks	50
4.3.3	Filtrado por confianza	50
4.4	Implementación del módulo de profundidad	51
4.4.1	Servidor local de Depth Anything 3	51
4.4.2	Consulta de profundidad en puntos anatómicos	51
4.4.3	Optimización de llamadas al modelo	51
4.5	Implementación con RealSense	51
4.5.1	Uso de RealSense como cámara RGB	52
4.5.2	Captura y procesamiento de frames	52
4.6	Publicación de datos en ROS2	53
4.6.1	Topics de imagen y landmarks	53
4.6.2	Topics de profundidad y acción	53
4.7	Implementación del puente ROS2–Android	54
4.8	Implementación de la aplicación Android	54
4.8.1	Recepción de acciones por WiFi	55
4.8.2	Envío de comandos por Bluetooth	55
4.8.3	Inicialización automática de velocidad	55
4.9	Implementación de la lógica de movimiento	55
4.9.1	Acciones simples	55
4.9.2	Acciones combinadas	56
4.9.3	Parada de seguridad	56
4.10	Problemas encontrados y soluciones aplicadas	56
5	Experimentación y validación	57
5.1	Metodología experimental	57
5.2	Pruebas de detección de pose	60
5.3	Pruebas de landmarks anatómicos	60
5.4	Pruebas de orientación del paciente	61
5.5	Pruebas iniciales de profundidad con Depth Anything 3	61
5.5.1	Lectura de profundidad en pelvis	62
5.5.2	Lectura de profundidad en base cervical	62
5.5.3	Comparación entre landmarks	62

5.6	Comparativa entre RealSense y Depth Anything 3	63
5.6.1	Tasa de valores válidos	63
5.6.2	Desviación típica temporal	64
5.6.3	Diferencia entre frames consecutivos	64
5.6.4	MAE	64
5.6.5	RMSE	64
5.6.6	MAPE	65
5.7	Validación de la profundidad como señal relativa	65
5.8	Pruebas de decisión de movimiento	66
5.8.1	Clasificación cerca, en rango y lejos	66
5.8.2	Centrado horizontal	66
5.8.3	Bloqueo de posición alcanzada	67
5.9	Pruebas de integración con MiniCERNBot	67
6	Resultados y discusión	69
6.1	Resultados del sistema de percepción	69
6.2	Resultados de la estimación de landmarks anatómicos	70
6.3	Resultados de la estimación de profundidad	70
6.4	Resultados de la comparativa RealSense–Depth Anything 3	70
6.5	Resultados del sistema de decisión	71
6.6	Resultados del movimiento autónomo del robot	71
6.7	Grado de consecución de los objetivos	72
6.8	Limitaciones del sistema	73
6.9	Discusión general	73
7	Conclusiones y trabajo futuro	75
7.1	Conclusiones	75
7.2	Aportaciones principales del proyecto	76
7.3	Limitaciones actuales	77
7.4	Líneas de trabajo futuro	77
7.4.1	Calibración de la profundidad monocular	77
7.4.2	Mejora de la robustez ante oclusiones	77
7.4.3	Entrenamiento o ajuste con imágenes hospitalarias	78
7.4.4	Integración completa en una plataforma robótica autónoma	78
7.4.5	Validación en escenarios más realistas	78
A	Material complementario del proyecto	79
A.1	Repositorio y estructura de archivos del proyecto	79
A.2	Comandos básicos de ejecución	80
A.3	Topics ROS2 publicados	80
A.4	Material complementario	81
A.5	Demostración en vídeo del sistema	81
	Bibliografía	83

Glosario de términos y abreviaturas

En este apartado se recogen los principales términos técnicos y abreviaturas empleados a lo largo de la memoria, con el objetivo de facilitar la lectura del documento.

Android: Sistema operativo utilizado en el dispositivo móvil que actúa como puente de comunicación entre el ordenador y el MiniCERNBot.

Bluetooth: Tecnología de comunicación inalámbrica utilizada para enviar comandos desde el dispositivo Android al robot MiniCERNBot.

CSV: Formato de archivo de texto empleado para almacenar datos tabulados. En este proyecto se utiliza para guardar resultados experimentales y métricas de validación.

DA3: Abreviatura de *Depth Anything 3*, modelo de estimación de profundidad monocular utilizado en este trabajo.

Depth Anything 3: Modelo de visión artificial capaz de estimar mapas de profundidad a partir de imágenes RGB. En este TFG se utiliza como fuente de profundidad relativa asociada a landmarks anatómicos externos.

Endpoint: Punto de acceso de un servicio local o remoto. En este proyecto se emplea para consultar el servidor local de Depth Anything 3 mediante peticiones HTTP.

FPS: Siglas de *frames per second*. Indican el número de imágenes o fotogramas procesados por segundo.

GPU: Unidad de procesamiento gráfico. Se utiliza para acelerar la ejecución de modelos de visión artificial como RTMPose y Depth Anything 3.

HTTP: Protocolo de comunicación utilizado para enviar peticiones entre procesos. En este trabajo se emplea para consultar el servidor local de Depth Anything 3.

IA: Inteligencia artificial. En este proyecto se aplica principalmente a modelos de visión artificial para estimación de pose humana y profundidad.

- Intel RealSense:** Cámara RGB-D utilizada en el proyecto como fuente de imagen RGB y como referencia experimental de profundidad.
- JSON:** Formato ligero de intercambio de datos. En este proyecto se utiliza para guardar y transmitir información sobre landmarks, orientación, profundidad y acciones generadas.
- Keypoint:** Punto corporal detectado por un modelo de estimación de pose humana. Puede representar partes como hombros, caderas, nariz, ojos, rodillas o muñecas.
- Landmark anatómico externo:** Referencia anatómica aproximada calculada a partir de keypoints corporales. En este trabajo se emplea para orientar el posicionamiento del robot, no como localización clínica exacta de órganos internos.
- MAE:** Siglas de *Mean Absolute Error*. Métrica que mide el error absoluto medio entre los valores estimados y una referencia real.
- MAPE:** Siglas de *Mean Absolute Percentage Error*. Métrica que expresa el error absoluto medio como porcentaje respecto al valor real de referencia.
- MMPose:** Herramienta del ecosistema OpenMMLab dedicada a la estimación de pose humana. En este proyecto se utiliza para integrar RTMPose.
- MiniCERNBot:** Plataforma robótica móvil utilizada para validar el movimiento autónomo generado por el sistema.
- Nodo ROS2:** Proceso independiente dentro de una arquitectura ROS2. Cada nodo puede publicar o recibir información mediante topics.
- OpenMMLab:** Ecosistema de herramientas de código abierto para visión artificial. En este TFG se utiliza principalmente a través de MMPose y RTMPose.
- Profundidad monocular:** Estimación de profundidad obtenida a partir de una única imagen RGB, sin utilizar un sensor físico de profundidad.
- Profundidad relativa:** Señal de proximidad utilizada para determinar si la persona se encuentra cerca, lejos o a una distancia adecuada, sin interpretarla necesariamente como una distancia métrica exacta.
- Publisher:** Componente de ROS2 encargado de publicar mensajes en un topic.
- RGB:** Imagen formada por tres canales de color: rojo, verde y azul. Es el tipo de imagen utilizado como entrada principal del sistema de percepción.
- RGB-D:** Tipo de cámara que combina imagen RGB con información de profundidad.
- RMSE:** Siglas de *Root Mean Square Error*. Métrica que mide la raíz del error cuadrático medio y penaliza más los errores grandes.
- ROS2:** Middleware robótico utilizado para organizar la comunicación entre módulos mediante nodos, mensajes y topics.
- RTMPose:** Modelo de estimación de pose humana orientado al tiempo real. En este TFG se utiliza para detectar keypoints corporales en imágenes RGB.
- Skeleton corporal:** Representación simplificada del cuerpo humano obtenida al conectar los keypoints detectados por un modelo de pose.

Subscriber: Componente de ROS2 encargado de recibir mensajes publicados en un topic.

TCP/WiFi: Comunicación de red utilizada para enviar las acciones generadas en el ordenador hacia la aplicación Android.

Topic: Canal de comunicación de ROS2 a través del cual los nodos publican o reciben mensajes.

Visión artificial: Área de la inteligencia artificial que permite extraer información útil a partir de imágenes o secuencias de vídeo.

1. Introducción

1.1 Contexto del proyecto

La robótica asistencial constituye una línea de trabajo de gran interés dentro de la ingeniería robótica, especialmente en aquellos entornos en los que un sistema autónomo puede servir como apoyo para mejorar la seguridad, la eficiencia o la precisión de determinadas tareas. En el ámbito hospitalario, este tipo de sistemas puede resultar útil en situaciones donde se requiere aproximar dispositivos, transportar material, asistir al personal sanitario o posicionarse frente a un paciente para facilitar una actuación posterior.

El presente Trabajo Final de Grado se enmarca dentro de una aplicación asistencial en la que un robot móvil debe ser capaz de situarse frente a una persona para permitir, en fases posteriores, la realización de mediciones de radiación en regiones anatómicas concretas, como la zona tiroidea y la región prostática. Este tipo de planteamiento puede resultar relevante en contextos médicos en los que sea necesario realizar mediciones localizadas y controlar la posición relativa entre el sistema de medida y el paciente.

No obstante, este TFG no aborda directamente la medición radiológica ni el desarrollo del sensor encargado de medir radiación. La contribución principal del trabajo se centra en la etapa previa necesaria para que dicha medición pueda realizarse en el futuro: la detección de referencias anatómicas externas y el posicionamiento autónomo del robot frente a la persona.

Con el fin de ilustrar el escenario de aplicación considerado, la Figura 1.1 muestra una representación conceptual del sistema propuesto. En ella se observa a un paciente situado en un entorno hospitalario y un robot móvil que se aproxima de forma controlada para colocarse frente a las regiones anatómicas externas de interés. La figura incluye también una vista esquemática de la percepción del robot, donde la imagen RGB se interpreta mediante estimación de pose humana, landmarks anatómicos externos y una acción de posicionamiento.

Para ello, se desarrolla una arquitectura basada en visión artificial capaz de detectar la pose humana, derivar landmarks anatómicos externos aproximados y utilizar esta información para guiar el movimiento del robot. La finalidad no es localizar clínicamente órganos internos, sino obtener referencias externas útiles que permitan al robot orientarse y situarse de forma adecuada frente al paciente.




Figura 1.1: Escenario conceptual de aplicación del sistema propuesto. Fuente: elaboración propia con apoyo de IA generativa.

El trabajo parte de una arquitectura previa desarrollada durante la estancia de prácticas, en la que se implementó un primer sistema de detección de pose humana mediante RTMPose y se definieron landmarks anatómicos externos a partir de los keypoints corporales detectados. Entre esos puntos se incluyeron referencias aproximadas de la zona tiroidea y prostática, calculadas mediante relaciones geométricas entre elementos visibles del cuerpo, como hombros, nariz y caderas.

A partir de esa base, este TFG amplía el sistema inicial incorporando estimación de profundidad, análisis de distancia relativa, lógica de decisión y generación de acciones de movimiento. Para ello se combinan distintos elementos: una cámara Intel RealSense utilizada como fuente RGB, el modelo RTMPose para la estimación humana, Depth Anything 3 para la estimación monocular de profundidad, ROS2 para la publicación y comunicación de datos, una aplicación Android como puente de comunicación y el robot MiniCERNBot como plataforma móvil final.

De este modo, el trabajo evoluciona desde un sistema centrado principalmente en la percepción hacia una arquitectura más completa de percepción, decisión y actuación. La información visual obtenida no solo se representa o almacena, sino que se transforma en acciones concretas de movimiento que permiten al robot acercarse, alejarse, detenerse o corregir lateralmente su posición frente a la persona.

1.2 Motivación

La motivación principal de este proyecto surge de la necesidad de desarrollar una etapa robótica previa que permita situar un sistema móvil frente a una persona de forma autónoma y controlada. En una aplicación médica futura, esta capacidad podría emplearse para colocar el robot en una posición adecuada antes de realizar mediciones de radiación en zonas de interés, como la región tiroidea o la región prostática.

Para que esta aplicación sea posible, el robot debe resolver primero varios problemas fundamentales. En primer lugar, debe detectar a la persona en la imagen. En segundo lugar, debe identificar referencias corporales útiles para la tarea. Además, debe estimar si la orientación de la persona es válida, calcular la distancia aproximada respecto al robot y transformar toda esta información en

decisiones de movimiento.

El interés del trabajo no reside únicamente en aplicar métodos de visión artificial de forma aislada, sino en integrarlos dentro de una cadena robótica funcional. Un modelo de estimación de pose puede detectar keypoints corporales, pero estos puntos por sí solos no indican cómo debe actuar el robot. Del mismo modo, una estimación de profundidad puede proporcionar información espacial, pero necesita ser interpretada, filtrada y conectada con una lógica de decisión para resultar útil en una aplicación real.

Por ello, este TFG se plantea como un trabajo de integración. La percepción visual se utiliza como entrada para construir una señal de posicionamiento, y esta señal se transforma posteriormente en acciones como acercarse, alejarse, desplazarse lateralmente o detenerse. Esta evolución permite pasar de una detección visual pasiva a una primera forma de comportamiento autónomo, en la que el robot responde a la posición y distancia estimadas respecto a la persona observada.

Además, el proyecto presenta un interés formativo claro, ya que combina distintas áreas del Grado en Inteligencia Robótica: visión artificial, aprendizaje automático, sensores, comunicaciones, dispositivos móviles, ROS2, integración software-hardware y robótica móvil. Por tanto, el trabajo no se limita a una única tecnología, sino que requiere coordinar varios módulos heterogéneos para construir una solución funcional.

1.3 Planteamiento del problema

El problema abordado en este trabajo puede formularse como la necesidad de desarrollar un sistema que permita a un robot móvil posicionarse de forma autónoma frente a una persona utilizando información visual y una arquitectura de comunicación distribuida.

La finalidad global del sistema es servir como etapa previa a una posible medición radiológica localizada. Para ello, el robot debe ser capaz de situarse frente a regiones anatómicas de interés, como la zona tiroidea o la región prostática. Sin embargo, antes de realizar cualquier medición, el sistema necesita resolver una tarea previa: detectar referencias anatómicas externas que permitan orientar el posicionamiento del robot.

Los modelos habituales de estimación de pose no proporcionan directamente landmarks anatómicos como "tiroides" o "próstata". En su lugar, devuelven keypoints estándar del cuerpo humano, como hombros, caderas, rodillas, nariz u ojos. Por tanto, resulta necesario definir una etapa adicional de postprocesado geométrico que permita calcular referencias anatómicas externas aproximadas a partir de estos puntos.

Además, debe tenerse en cuenta que una cámara RGB no permite observar órganos internos. Por ese motivo, el trabajo no pretende estimar la posición clínica real de la tiroides o la próstata, sino aproximar regiones anatómicas externas asociadas a dichas zonas. Estas referencias tienen utilidad desde el punto de vista del guiado, la orientación y el posicionamiento relativo del robot, pero no deben interpretarse como una herramienta diagnóstica ni como un sistema médico de localización anatómica precisa.

Otro de los retos principales es la estimación de la distancia. La detección 2D permite conocer la posición de un punto en la imagen, pero no proporciona por sí sola la separación entre el robot y la persona. Para abordar esta limitación, se estudia el uso de profundidad monocular mediante Depth Anything 3 y se compara con la profundidad proporcionada por la cámara RealSense. Las pruebas realizadas muestran que la profundidad no debe utilizarse de forma ingenua como una medida perfecta, sino que requiere análisis, suavizado temporal e interpretación según el objetivo del sistema.

Finalmente, el sistema debe transformar la información obtenida en acciones de movimiento. Esto implica definir una lógica de decisión que combine la distancia estimada y el centro horizontal del landmark seleccionado. Si la persona se encuentra demasiado lejos, el robot debe acercarse; si

está demasiado cerca, debe alejarse; si está en una distancia adecuada, debe detenerse; y si el punto anatómico aparece descentrado en la imagen, el robot debe corregir su posición lateral.

Además, para evitar oscilaciones provocadas por pequeñas variaciones en la estimación de profundidad, resulta necesario incorporar mecanismos de estabilización y bloqueo de posición alcanzada. De esta manera, el robot no reacciona de forma brusca ante cambios mínimos o ruido en la señal, sino que mantiene una posición estable hasta que detecta una variación suficientemente significativa.

1.4 Objetivos

1.4.1 Objetivo general

El objetivo general de este Trabajo Final de Grado es desarrollar y validar una arquitectura de percepción y posicionamiento autónomo para un robot móvil asistencial, capaz de detectar landmarks anatómicos externos de interés y situarse frente a una persona como etapa previa a futuras tareas de medición radiológica.

1.4.2 Objetivos específicos

Para alcanzar el objetivo general, se plantean los siguientes objetivos específicos:

- Estudiar y seleccionar un modelo de estimación de pose humana adecuado para la detección del esqueleto externo de una persona en un contexto experimental.
- Implementar un sistema de detección de pose basado en RTMPose y adaptarlo a una arquitectura de procesamiento en tiempo real.
- Definir landmarks anatómicos externos a partir de los keypoints corporales detectados, especialmente en la zona cervical y pélvica.
- Diferenciar claramente entre la detección de referencias anatómicas externas para posicionamiento robótico y la localización clínica real de órganos internos.
- Incorporar criterios de validación de orientación de la persona para determinar cuándo la medición puede considerarse válida.
- Integrar un sistema de estimación de profundidad monocular mediante Depth Anything 3 para obtener una señal de distancia asociada a los landmarks anatómicos.
- Comparar la profundidad estimada mediante Depth Anything 3 con la profundidad obtenida mediante RealSense, analizando métricas como disponibilidad de datos, estabilidad temporal, error absoluto medio, RMSE y MAPE.
- Diseñar una lógica de decisión que clasifique la posición de la persona en función de la distancia estimada y del centro horizontal en la imagen.
- Publicar la información relevante mediante ROS2 para facilitar la comunicación entre los distintos módulos del sistema.
- Implementar un puente de comunicación entre ROS2, una aplicación Android y el robot MiniCERNBot.
- Validar experimentalmente que el robot puede ejecutar acciones de aproximación, alejamiento, parada y corrección lateral a partir de la percepción visual.

1.5 Alcance y limitaciones del proyecto

El alcance del proyecto se centra en el desarrollo de una primera arquitectura funcional de percepción y posicionamiento asistido. El sistema propuesto permite detectar una persona, calcular referencias anatómicas externas, estimar una señal de distancia relativa y generar acciones de movimiento para un robot móvil.

Aunque la aplicación final prevista está relacionada con la realización de mediciones de radiación en regiones anatómicas de interés, este TFG no implementa ni valida ningún sistema de medición radiológica. Por tanto, el trabajo realizado debe entenderse como una etapa previa dentro de una arquitectura más amplia. Su objetivo es preparar al robot para situarse correctamente frente a la persona, no realizar la medición médica final.

En primer lugar, las referencias anatómicas calculadas no representan la localización exacta de órganos internos. La tiroides y la próstata no son visibles directamente mediante una cámara RGB, por lo que los puntos empleados en este trabajo deben entenderse como landmarks anatómicos externos aproximados, derivados geoméricamente a partir de keypoints corporales. Estos landmarks no tienen una finalidad diagnóstica ni pretenden sustituir a técnicas clínicas de localización anatómica, sino proporcionar una referencia suficientemente útil para el posicionamiento del robot y para delimitar, en fases posteriores, una zona externa de medición radiológica alrededor de las regiones de interés.

En segundo lugar, la estimación de profundidad mediante Depth Anything 3 se utiliza principalmente como una señal relativa de proximidad. Aunque el modelo permite obtener valores asociados a la profundidad de la escena, las pruebas realizadas indican que estos valores no deben interpretarse necesariamente como una medida métrica exacta sin calibración previa. Por esta razón, en la arquitectura final se emplean umbrales experimentales y mecanismos de suavizado para clasificar la distancia en estados prácticos, como cerca, distancia correcta o lejos.

En tercer lugar, el sistema ha sido validado en condiciones experimentales controladas, por lo que su funcionamiento en un entorno hospitalario real requeriría pruebas adicionales. Factores como la iluminación, la ropa del paciente, las oclusiones, la posición de la cámara, la presencia de otras personas o las variaciones posturales pueden afectar al rendimiento del sistema.

Por último, el comportamiento autónomo implementado se limita a acciones básicas de posicionamiento: acercarse, alejarse, detenerse y corregir lateralmente la posición. No se aborda en este trabajo una navegación autónoma completa en entornos complejos, ni la planificación global de trayectorias, ni la interacción clínica real con pacientes.

1.6 Planificación del trabajo

El desarrollo del proyecto se ha organizado de forma progresiva, partiendo del trabajo previo realizado durante la estancia en prácticas y avanzando posteriormente hacia la integración de profundidad, decisión y movimiento autónomo. Dado que el proyecto combina visión artificial, estimación de profundidad, comunicación entre sistemas y control robótico, la planificación no se planteó como una secuencia completamente cerrada, sino como un proceso iterativo en el que cada fase permitió validar una parte del sistema antes de avanzar hacia la siguiente.

1.6.1 Fases de desarrollo

En una primera fase, se consolidó el sistema de percepción basado en RTMPose. Esta etapa consistió en detectar la pose humana en imagen, trabajar con los keypoints corporales proporcionados por el modelo y definir landmarks anatómicos externos relacionados con la zona tiroidea y la región prostática. Además, se estableció una arquitectura capaz de publicar los resultados en ROS2, lo que permitió disponer de una base funcional sobre la que construir los módulos posteriores.

En una segunda fase, se estudió la estimación de profundidad mediante Depth Anything 3. Inicialmente se realizaron pruebas offline con secuencias de vídeo e imágenes, con el objetivo de comprobar si la profundidad estimada variaba de forma coherente cuando la persona se encontraba más cerca o más lejos de la cámara. Posteriormente, se automatizó la lectura de profundidad en landmarks concretos y se analizaron diferentes referencias corporales para determinar cuáles ofrecían una señal más estable.

En una tercera fase, se comparó la profundidad obtenida mediante Depth Anything 3 con la profundidad proporcionada por la cámara RealSense. Esta comparación permitió observar diferencias entre ambos métodos. Por un lado, RealSense ofrecía una medida más adecuada desde el punto de vista métrico. Por otro lado, Depth Anything 3 proporcionaba una señal útil como referencia relativa de proximidad, especialmente cuando se aplicaba suavizado temporal y se interpretaba mediante umbrales experimentales.

En una cuarta fase, se integró la cadena completa de percepción y decisión en tiempo real. Para ello, la RealSense se utilizó como cámara RGB, RTMPose calculó los landmarks anatómicos, Depth Anything 3 estimó la profundidad asociada a dichos puntos y ROS2 publicó los estados y acciones generadas por el sistema. Esta fase permitió transformar la información visual en decisiones como acercarse, alejarse, detenerse o corregir lateralmente la posición del robot.

Finalmente, en una quinta fase, se conectó la salida de ROS2 con la aplicación Android y con el robot MiniCERNBot. Esta etapa permitió validar que las acciones generadas por la percepción visual podían traducirse en movimiento real del robot mediante una comunicación distribuida basada en ROS2, TCP/WiFi, Android y Bluetooth. Con ello se consiguió una primera integración funcional entre percepción, decisión y actuación robótica.

1.6.2 Desviaciones respecto a la planificación inicial

Aunque el desarrollo siguió una progresión lógica, durante el proyecto aparecieron varias desviaciones respecto a la planificación inicial. Estas desviaciones no supusieron un abandono del objetivo principal, sino una adaptación necesaria a los problemas técnicos encontrados durante la integración del sistema.

Una de las primeras desviaciones estuvo relacionada con los entornos de ejecución. La integración directa entre RTMPose, ROS2 y Depth Anything 3 en un único entorno no resultó viable debido a incompatibilidades entre versiones de Python, dependencias de OpenMMLab, librerías de ROS2 y requisitos del modelo de profundidad. Como consecuencia, se optó por una arquitectura modular basada en procesos separados, donde cada parte del sistema se ejecuta en el entorno más adecuado y se comunica mediante ficheros, servicios locales o topics de ROS2.

Otra desviación importante fue el cambio en el uso de la cámara RealSense. Inicialmente se contempló la posibilidad de utilizar tanto su imagen RGB como su profundidad. Sin embargo, las pruebas realizadas mostraron que la lectura local de profundidad de RealSense en torno a landmarks anatómicos concretos podía presentar variaciones importantes entre fotogramas, valores no válidos y saltos bruscos. Aunque algunos valores individuales fueran métricamente correctos, esta variabilidad no resultaba adecuada para alimentar directamente la lógica final de movimiento del robot. Por ello, la RealSense acabó utilizándose principalmente como cámara RGB, mientras que la estimación de profundidad empleada para la toma de decisiones se basó en Depth Anything 3, interpretado como una señal relativa de proximidad.

También se produjo una evolución en la forma de interpretar la profundidad. En un primer momento, se estudió la posibilidad de utilizar los valores de profundidad como medidas métricas directas. No obstante, los resultados mostraron que Depth Anything 3 no debía emplearse como una distancia exacta sin calibración previa. Por esta razón, el sistema final utiliza umbrales experimentales y suavizado temporal para clasificar la distancia en estados funcionales, como cerca, distancia adecuada o lejos.

Asimismo, la lógica de movimiento tuvo que modificarse durante el desarrollo. Al principio se planteaban acciones simples, como acercarse, alejarse o parar. Sin embargo, al avanzar en las pruebas se observó que también era necesario corregir el centrado horizontal del robot respecto a la persona. Por ello, se incorporaron acciones laterales y acciones combinadas, permitiendo que el robot no solo regule su distancia, sino que también se coloque de forma más alineada frente al landmark anatómico seleccionado.

Por último, se añadió una capa de estabilización mediante bloqueo de posición alcanzada. Esta modificación fue necesaria porque pequeñas fluctuaciones en la estimación de profundidad podían provocar oscilaciones en la acción del robot, alternando entre avanzar, parar o retroceder aunque la persona y el robot estuvieran prácticamente quietos. Con el bloqueo de posición, el robot mantiene la parada cuando alcanza una posición válida y solo vuelve a moverse si detecta un cambio suficientemente significativo.

En conjunto, estas desviaciones reflejan el carácter experimental e integrador del proyecto. La planificación inicial sirvió como guía general, pero el desarrollo real exigió reajustes continuos para lograr una arquitectura funcional, estable y coherente con los objetivos del TFG.

1.6.3 Diagrama de Gantt

La planificación temporal del proyecto se recoge en el diagrama de Gantt incluido en esta sección. En él se representan las principales fases de trabajo desarrolladas durante el TFG: consolidación del sistema de percepción, integración de landmarks anatómicos, pruebas de profundidad, comparación entre RealSense y Depth Anything 3, implementación de la lógica de decisión, integración con ROS2, comunicación con Android, validación con MiniCERNBot y redacción de la memoria.




Figura 1.2: Diagrama de Gantt de la planificación temporal del TFG. Fuente: elaboración propia.

El diagrama muestra la distribución temporal de las tareas y permite observar que varias fases se desarrollaron de manera parcialmente solapada. Esto se debe a que el proyecto requirió un proceso iterativo de prueba, corrección y validación, especialmente en las partes relacionadas con la integración entre visión artificial, profundidad, comunicación entre dispositivos y movimiento real del robot.

Además, el diagrama refleja que algunas tareas inicialmente previstas como fases independientes tuvieron que reajustarse durante el desarrollo. En particular, la comparación entre RealSense y

Depth Anything 3, la estabilización de la señal de profundidad y la lógica de decisión del robot evolucionaron a medida que se obtenían resultados experimentales. Por ello, la planificación final no representa una secuencia completamente lineal, sino un proceso progresivo de integración y mejora del sistema.

1.7 Estimación de costes

La estimación de costes del proyecto se ha realizado considerando el coste aproximado que supondría reproducir una arquitectura similar a la desarrollada en este TFG. Aunque durante el trabajo varios recursos ya estaban disponibles en el laboratorio o eran dispositivos personales, resulta conveniente valorar económicamente los principales elementos necesarios para implementar el sistema en un entorno equivalente.

El proyecto combina recursos hardware, herramientas software, tiempo de desarrollo y tareas de supervisión. En la parte hardware se incluyen los dispositivos necesarios para la captura de imagen, el procesamiento de los modelos de visión artificial, la comunicación entre módulos y la validación del movimiento sobre una plataforma robótica. En cuanto al software, se han empleado principalmente herramientas gratuitas, de código abierto o de uso académico, por lo que no se consideran costes directos de licencia. Finalmente, se contempla también el coste asociado al trabajo de desarrollo, ya que la integración de los distintos componentes constituye una parte fundamental del proyecto.

Los costes indicados tienen carácter orientativo y se han estimado a partir de precios de mercado consultados durante la redacción del trabajo. En el caso de la cámara Intel RealSense, se ha tomado como referencia el precio de modelos de la familia D435i disponibles en distribuidores oficiales. Para el equipo de procesamiento, se han considerado ordenadores con GPU dedicada capaces de ejecutar modelos de visión artificial como RTMPose y Depth Anything 3. En el caso del dispositivo Android, se ha tomado como referencia un teléfono de gama media suficiente para actuar como puente de comunicación con el robot (PcComponentes, 2026a, 2026b; RealSense, 2026).

La Tabla 1.1 muestra una estimación orientativa de los costes materiales principales.

Tabla 1.1: Estimación orientativa de costes materiales del proyecto.

Concepto	Descripción	Coste estimado
Cámara Intel RealSense	Cámara utilizada como fuente RGB para el sistema de percepción	350 € - 450 €
Equipo de procesamiento	Ordenador con capacidad suficiente para ejecutar RTMPose, Depth Anything 3 y ROS2	1.200 € - 1.800 €
Dispositivo Android	Teléfono empleado como puente de comunicación con el robot	200 € - 300 €
Plataforma robótica MiniCERNBot	Robot móvil utilizado para validar el posicionamiento autónomo	Disponible en laboratorio
Cableado y accesorios	Cables, adaptadores, soportes y elementos auxiliares de conexión	50 € - 150 €
Software	Python, ROS2, OpenMMLab, RTMPose, Depth Anything 3 y Android Studio	0 €

Además de los costes materiales, resulta necesario considerar el coste laboral asociado al desarrollo del proyecto. Aunque en el contexto académico este coste no se imputa como un gasto real, sí permite valorar de forma más completa el esfuerzo necesario para llevar a cabo la instalación de entornos, la programación, la integración de módulos, la realización de pruebas, el análisis de resultados y la redacción de la memoria.

Para esta estimación se ha considerado una dedicación aproximada de 300 horas de trabajo

por parte de una ingeniera junior, correspondiente al desarrollo técnico y documental del TFG. Asimismo, se incluye una estimación de 20 horas de supervisión por parte de una persona sénior, asociadas al seguimiento, orientación técnica y revisión del proyecto. Los costes horarios empleados tienen carácter orientativo y no representan una facturación real, sino una aproximación para valorar económicamente el trabajo desarrollado.

La Tabla 1.2 recoge la estimación del coste laboral asociado al proyecto.

Tabla 1.2: Estimación orientativa del coste laboral del proyecto.

Perfil	Horas estimadas	Coste horario	Coste estimado
Ingeniera junior / estudiante en prácticas	300 h	15 €/h	4.500 €
Supervisión sénior / tutoría técnica	20 h	40 €/h	800 €
Total coste laboral	320 h	–	5.300 €

A estos costes se añade una estimación de costes indirectos, asociados a consumo eléctrico, conexión a internet, uso de instalaciones, mantenimiento básico de equipos y otros gastos generales. En esta memoria se ha considerado un porcentaje fijo del 10 % sobre los costes directos, entendido como una aproximación razonable dentro del contexto académico del proyecto.

La Tabla 1.3 resume la estimación global del proyecto, considerando el coste material principal, el coste laboral y los costes indirectos. Dado que algunos elementos presentan un rango de precios, se muestran valores mínimos y máximos aproximados.

Tabla 1.3: Estimación global orientativa del coste del proyecto.

Concepto	Estimación mínima	Estimación máxima
Costes materiales principales	1.800 €	2.700 €
Coste laboral estimado	5.300 €	5.300 €
Costes directos totales	7.100 €	8.000 €
Costes indirectos estimados (10 %)	710 €	800 €
Coste total estimado	7.810 €	8.800 €

En el caso concreto de este TFG, la cámara RealSense, la plataforma robótica y otros elementos auxiliares estaban disponibles en el laboratorio. Por otra parte, el ordenador de procesamiento y el teléfono Android utilizados durante las pruebas eran dispositivos personales. Por este motivo, el coste económico directo asociado a la adquisición de material fue reducido.

No obstante, si el sistema tuviera que reproducirse desde cero en otro entorno, habría que considerar la adquisición del hardware principal, especialmente la cámara, el equipo de procesamiento y una plataforma robótica móvil equivalente. A estos elementos se añadiría el coste del tiempo de desarrollo necesario para instalar los entornos, integrar los modelos de visión artificial, resolver incompatibilidades entre dependencias, configurar la comunicación entre ROS2 y Android, realizar las pruebas experimentales y ajustar la lógica de decisión del robot.

Desde el punto de vista del software, no se han considerado costes de licencia, ya que las herramientas utilizadas son gratuitas o de código abierto. Sin embargo, esto no implica que su uso no haya supuesto esfuerzo técnico. La instalación y configuración de entornos como OpenMMLab, ROS2 o Depth Anything 3 requirió tiempo de prueba y depuración, especialmente debido a las incompatibilidades entre versiones de Python, dependencias de visión artificial y librerías asociadas a ROS2.

Por tanto, el coste real directo del proyecto fue bajo dentro del contexto académico en el que se desarrolló, pero el coste de reproducción del sistema dependería de los recursos ya disponibles en

el entorno de trabajo. Considerando únicamente los costes materiales principales, la reproducción del sistema se situaría aproximadamente entre 1.800 € y 2.700 €, sin incluir la adquisición de una plataforma robótica equivalente. Si además se valora el tiempo de desarrollo, supervisión y costes indirectos, el coste total orientativo del proyecto se situaría aproximadamente entre 7.810 € y 8.800 €.

1.8 Estructura del documento

El presente documento se organiza en varios capítulos que describen de forma progresiva el contexto, el diseño, la implementación y la validación del sistema desarrollado.

En el primer capítulo se presenta la introducción del trabajo. En ella se expone el contexto general del proyecto, la motivación, el planteamiento del problema, los objetivos, el alcance y las limitaciones, la planificación temporal y la estimación de costes. Este capítulo permite situar el TFG dentro de una aplicación asistencial orientada al posicionamiento de un robot móvil frente a una persona como etapa previa a futuras mediciones radiológicas localizadas.

El segundo capítulo recoge el marco teórico y el estado del arte. En él se abordan los fundamentos de la estimación de pose humana, los modelos considerados, la problemática de la oclusión, la obtención de landmarks anatómicos externos y las técnicas de estimación de profundidad empleadas en el proyecto. También se justifica la selección de RTMPose y Depth Anything 3 dentro de la arquitectura desarrollada.

El tercer capítulo está dedicado al análisis y diseño del sistema. En este apartado se describen los requisitos funcionales y no funcionales, la arquitectura general, el diseño del módulo de percepción, la definición de landmarks anatómicos externos, la validación de la orientación de la persona, el módulo de profundidad, la lógica de decisión y la comunicación entre los distintos componentes.

El cuarto capítulo describe la implementación del sistema. En él se detallan los elementos hardware y software utilizados, los entornos de ejecución, la integración de RTMPose, Depth Anything 3, RealSense, ROS2, Android y MiniCERNBot, así como los principales problemas técnicos encontrados y las soluciones aplicadas durante el desarrollo.

El quinto capítulo presenta la experimentación y validación. En este capítulo se describen las pruebas realizadas sobre la detección de pose, la lectura de profundidad en landmarks anatómicos, la comparación entre RealSense y Depth Anything 3, la clasificación de distancia, la generación de acciones de movimiento y la validación del sistema completo sobre el robot.

El sexto capítulo recoge los resultados y la discusión. En él se analiza el grado de consecución de los objetivos, la utilidad de los landmarks anatómicos externos, el comportamiento de la profundidad como señal relativa, la respuesta del sistema de decisión y las limitaciones observadas durante las pruebas.

Finalmente, el documento concluye con un capítulo de conclusiones y trabajo futuro. En él se resumen las principales aportaciones del proyecto y se plantean posibles líneas de continuación, como la mejora de la robustez ante oclusiones, la calibración de la profundidad monocular, la validación en escenarios más realistas y la futura integración de sensores destinados a la medición radiológica.

2. Marco teórico y estado del arte

2.1 Robótica asistencial en entornos hospitalarios

La robótica asistencial en entornos hospitalarios constituye un ámbito de aplicación en el que los sistemas robóticos se utilizan como apoyo a tareas clínicas, logísticas o de interacción con pacientes. Aunque una parte importante de la robótica médica se ha desarrollado tradicionalmente en torno a la cirugía asistida, el uso de robots en sanidad abarca también otras funciones, como rehabilitación, telepresencia, transporte, desinfección, farmacia, radioterapia o asistencia en procedimientos de imagen e intervención (Morgan et al., 2022).

En este contexto, el presente trabajo se sitúa dentro de una línea de robótica asistencial orientada al posicionamiento de un robot móvil frente a una persona. La finalidad global de la aplicación es que el robot pueda situarse delante del paciente y emplear referencias anatómicas externas para facilitar, en fases posteriores, mediciones de radiación en zonas próximas a regiones anatómicas de interés, como la zona tiroidea o la región prostática.

No obstante, el alcance de este TFG no incluye el desarrollo ni la validación de un sistema de medición radiológica. El trabajo se centra en la etapa previa necesaria para que dicha medición pueda plantearse posteriormente: la detección de la persona, la obtención de referencias anatómicas externas, la estimación de una distancia relativa y la generación de acciones de movimiento para posicionar el robot de forma adecuada.

De este modo, el robot no se plantea como un sistema médico autónomo completo, sino como una plataforma móvil capaz de utilizar información visual para colocarse en una posición útil respecto al paciente. Esta orientación permite abordar el problema desde una perspectiva de integración robótica, combinando percepción, comunicación y control de movimiento.

2.2 Prelocalización anatómica externa

En este trabajo se utiliza el término prelocalización anatómica externa para referirse a la estimación aproximada de regiones corporales visibles o inferibles a partir de la estructura externa del cuerpo. Esta idea debe diferenciarse claramente de la localización clínica precisa de órganos internos. Una cámara RGB convencional no permite observar directamente estructuras internas

como la tiroides o la próstata, por lo que el sistema no pretende determinar su posición anatómica exacta.

En su lugar, se calculan landmarks anatómicos externos aproximados a partir de keypoints corporales detectados mediante estimación de pose humana. Estos landmarks sirven como referencias espaciales para que el robot pueda situarse frente a la persona y orientar, en una fase posterior, una posible medición radiológica sobre una zona externa cercana a dichas regiones anatómicas.

Por tanto, la utilidad de estos puntos no reside en proporcionar una localización médica exacta, sino en ofrecer una referencia suficientemente coherente para el posicionamiento del robot. En este sentido, la precisión requerida no es la misma que en un sistema de imagen médica, ya que la futura medición de radiación se realizaría sobre una zona alrededor del punto estimado y no necesariamente sobre un punto anatómico exacto.

Este enfoque resulta adecuado para una primera fase experimental, ya que permite utilizar modelos de pose humana ya existentes y aplicar posteriormente reglas geométricas sencillas para derivar referencias de interés. De esta forma, el sistema puede calcular puntos como la base cervical, la región tiroidea aproximada, el centro pélvico o la región prostática aproximada sin necesidad de entrenar inicialmente un modelo específico de landmarks médicos.

2.3 Estimación de pose humana

La estimación de pose humana es una tarea de visión por computador cuyo objetivo es localizar puntos clave del cuerpo humano en imágenes o secuencias de vídeo. Estos puntos suelen representar articulaciones o referencias anatómicas externas, como hombros, caderas, rodillas, tobillos, ojos, nariz o muñecas. A partir de ellos es posible construir una representación simplificada del cuerpo, habitualmente denominada skeleton o esqueleto corporal (Zheng et al., 2023).

En el contexto de este proyecto, la estimación de pose humana constituye la base del sistema de percepción. El objetivo no es únicamente dibujar el esqueleto de la persona, sino utilizar los keypoints detectados para calcular referencias anatómicas externas que puedan emplearse en el posicionamiento del robot. Por ello, el modelo de pose actúa como una primera etapa de extracción de información corporal, sobre la que posteriormente se aplica una fase de postprocesado geométrico.

2.3.1 Concepto de keypoints y skeleton corporal

Los keypoints son puntos definidos por el modelo de pose que representan partes concretas del cuerpo. En los modelos actuales, cada keypoint suele incluir sus coordenadas en la imagen y una puntuación de confianza asociada a la detección. La documentación de Ultralytics describe la salida de los modelos de pose como un conjunto de puntos que representan keypoints del objeto, normalmente acompañados de una confianza para cada punto (Ultralytics, 2026).

El skeleton corporal se obtiene al conectar determinados keypoints siguiendo una estructura predefinida. Esta representación permite visualizar la postura general de la persona y analizar relaciones espaciales entre distintas partes del cuerpo. En este proyecto, dichas relaciones se utilizan para calcular landmarks anatómicos externos derivados. Por ejemplo, la base cervical se calcula como el punto medio entre ambos hombros, mientras que el centro pélvico se obtiene a partir del punto medio entre ambas caderas.

Es importante destacar que los landmarks utilizados en este TFG no son salidas directas del modelo de pose. El modelo proporciona keypoints estándar, mientras que los landmarks anatómicos externos son referencias específicas del proyecto. Por tanto, entre la estimación de pose y el uso robótico de la información existe una etapa intermedia de filtrado, validación y cálculo geométrico.

2.3.2 Problemas de oclusión y ropa hospitalaria

Uno de los principales retos de la estimación de pose humana en escenarios reales es la oclusión. La detección de keypoints puede degradarse cuando una parte del cuerpo queda oculta por la postura, por otros objetos, por la perspectiva de la cámara o por la ropa. Los trabajos de revisión sobre estimación de pose humana identifican la oclusión, las ambigüedades de profundidad y la variabilidad de escenarios como problemas relevantes dentro del área (Zheng et al., 2023).

Este problema resulta especialmente importante en un contexto hospitalario, donde el paciente puede vestir prendas holgadas, como batas. Este tipo de ropa puede alterar el contorno visible del cuerpo y dificultar la detección estable de regiones como el cuello, el tronco o la pelvis. En el caso de este TFG, estas zonas son especialmente relevantes porque de ellas se derivan landmarks anatómicos como la región tiroidea aproximada o la región prostática aproximada.

Por este motivo, no basta con aplicar directamente el modelo de pose. Es necesario incorporar criterios de fiabilidad, como el filtrado por confianza de los keypoints, la validación de la orientación de la persona y el suavizado temporal de las medidas en secuencias de vídeo. Estas estrategias permiten reducir el impacto de detecciones inestables y mejorar la utilidad de los landmarks en una arquitectura robótica.

2.4 Modelos de estimación de pose

Existen distintos modelos y herramientas para estimación de pose humana. En este trabajo se revisaron cuatro alternativas principales: YOLO-Pose, RTMPose, ViTPose y OpenPose. La comparación se realizó teniendo en cuenta criterios como precisión, velocidad, facilidad de integración, adecuación al tiempo real y utilidad dentro de una arquitectura experimental.

2.4.1 YOLO-Pose

YOLO-Pose representa una alternativa atractiva cuando se prioriza la simplicidad de integración y la rapidez de prototipado. El ecosistema Ultralytics proporciona soporte para tareas de estimación de pose y permite utilizar modelos capaces de detectar keypoints corporales dentro de un pipeline unificado (Ultralytics, 2026).

Su principal ventaja es la accesibilidad. Al estar integrado en una familia de modelos ampliamente utilizada, permite desarrollar rápidamente una primera versión funcional de un sistema de detección de pose. Esta característica lo convierte en una opción interesante como línea base o baseline inicial.

Sin embargo, para este proyecto se buscaba una alternativa que ofreciera un equilibrio más específico entre precisión, velocidad y flexibilidad experimental. Aunque YOLO-Pose podía resultar útil como referencia comparativa, se consideró que RTMPose ofrecía una base más adecuada para trabajar con modelos de pose humana dentro de un ecosistema especializado como MMPose.

2.4.2 RTMPose

RTMPose es un framework de estimación de pose humana orientado al tiempo real y desarrollado sobre el ecosistema MMPose. Su objetivo es reducir la distancia entre los buenos resultados obtenidos en benchmarks y las necesidades prácticas de despliegue, donde resultan importantes tanto la precisión como la velocidad de inferencia (Jiang et al., 2023).

El papel de RTMPose dentro de este TFG consiste en transformar una imagen RGB de entrada en una representación estructurada del cuerpo humano mediante keypoints corporales. Estos keypoints no constituyen todavía los landmarks anatómicos finales utilizados por el sistema, sino una etapa intermedia. A partir de ellos se calculan posteriormente referencias externas específicas del proyecto, como la región tiroidea aproximada o la región prostática aproximada.

La Figura 2.1 muestra de forma conceptual este flujo de trabajo. En primer lugar, el sistema recibe una imagen RGB capturada desde la perspectiva del robot. A continuación, RTMPose procesa la imagen y estima los keypoints corporales visibles. Finalmente, a partir de esos puntos se calculan landmarks anatómicos externos que pueden emplearse para orientar el posicionamiento del robot frente a la persona.




Figura 2.1: Esquema conceptual del uso de RTMPose en el sistema propuesto. Elaborado con apoyo de IA generativa.

El trabajo original de RTMPose reporta resultados especialmente relevantes para aplicaciones en tiempo real. En concreto, RTMPose-m alcanza 75.8 AP en COCO con más de 90 FPS en una CPU Intel i7-11700 y más de 430 FPS en una GPU NVIDIA GTX 1660 Ti (Jiang et al., 2023). Estos datos muestran que el modelo está diseñado para funcionar con baja latencia y un rendimiento adecuado, lo cual resulta importante en un sistema que debe procesar imágenes de forma continua y generar decisiones de movimiento.

Otra razón importante para seleccionar RTMPose fue su integración con MMPose. MMPose es una herramienta open source de estimación de pose basada en PyTorch y desarrollada dentro de OpenMMLab (OpenMMLab, 2026). Esto facilita la experimentación con configuraciones, checkpoints, demos, inferencia sobre imágenes o webcam y adaptación del pipeline a scripts propios. En este TFG, esta característica fue especialmente útil porque permitió integrar el modelo dentro de una arquitectura Python propia y combinarlo posteriormente con el cálculo de landmarks anatómicos externos.

Por tanto, RTMPose se eligió como modelo principal porque ofrecía un equilibrio adecuado entre precisión, velocidad, disponibilidad de modelos preentrenados, documentación, integración con OpenMMLab y viabilidad de uso en una arquitectura experimental en tiempo real. Aunque otras alternativas podían ser válidas, RTMPose proporcionaba una solución suficientemente robusta y práctica para transformar keypoints corporales en referencias anatómicas externas utilizables por el robot.

2.4.3 ViTPose

ViTPose es una familia de modelos de estimación de pose basada en Vision Transformers. Su interés principal reside en mostrar que una arquitectura transformer relativamente simple puede obtener resultados competitivos en estimación de pose humana. El trabajo original destaca propiedades como la escalabilidad del tamaño del modelo, la flexibilidad del entrenamiento y la capacidad de transferencia entre configuraciones (Xu et al., 2022).

En el contexto de este proyecto, ViTPose se consideró una alternativa de alta precisión y una referencia académica relevante. Sin embargo, su mayor coste computacional y su menor orientación a una integración rápida dentro del sistema desarrollado hicieron que no se seleccionara como modelo principal. Por ello, se mantuvo como referencia comparativa de alta capacidad, pero no como base de implementación.

2.4.4 OpenPose

OpenPose es una de las referencias clásicas en estimación de pose humana. El trabajo asociado presenta un sistema en tiempo real para detección multipersona en 2D mediante Part Affinity Fields, incluyendo keypoints de cuerpo, pies, manos y cara (Cao et al., 2021). Su importancia histórica dentro del área es clara, ya que durante años ha sido una de las herramientas más reconocidas para detección de pose multipersona.

No obstante, en el contexto actual existen alternativas más recientes con mejores compromisos entre facilidad de despliegue, velocidad, integración y mantenimiento. En este TFG, OpenPose se valoró principalmente como referencia histórica y comparativa, pero no como la opción más conveniente para una arquitectura basada en OpenMMLab, ROS2 y procesamiento en tiempo real.

2.5 Selección del modelo de pose para el proyecto

La selección del modelo de pose se realizó considerando tanto aspectos técnicos como prácticos. Desde el punto de vista técnico, el sistema necesitaba detectar de forma fiable keypoints corporales relevantes para calcular landmarks externos. Desde el punto de vista práctico, era necesario que el modelo pudiera ejecutarse en un entorno experimental, integrarse con scripts propios y funcionar con una latencia aceptable.

La Tabla 2.1 resume la comparación entre los modelos considerados.

Tabla 2.1: Comparación de modelos de estimación de pose humana

Modelo	Fortalezas	Limitaciones	Papel en el proyecto
YOLO-Pose	Integración sencilla, rapidez de prototipado y soporte dentro del ecosistema Ultralytics.	Menor especialización para experimentación avanzada en pose frente a herramientas específicas.	Baseline funcional posible.
RTMPose	Buen equilibrio entre precisión y velocidad, orientación al tiempo real e integración con MMPose.	Requiere configurar el entorno OpenMMLab y sus dependencias.	Modelo seleccionado.
ViTPose	Alta precisión y valor como referencia basada en transformers.	Mayor coste computacional y menor comodidad para una integración rápida.	Referencia de alta precisión.
OpenPose	Referencia clásica, detección multipersona y soporte de cuerpo, cara, manos y pies.	Enfoque más antiguo frente a alternativas recientes.	Referencia histórica.

A partir de esta comparación, se seleccionó RTMPose como modelo principal del proyecto.

La decisión se fundamentó en tres razones principales. En primer lugar, ofrece un rendimiento adecuado para tiempo real, aspecto necesario para que el robot pueda reaccionar a la posición de la persona. En segundo lugar, está integrado en MMPose, lo que facilita el uso de modelos preentrenados, demos y herramientas de inferencia. En tercer lugar, proporciona una salida de keypoints suficientemente estructurada para aplicar el postprocesado geométrico necesario para obtener landmarks anatómicos externos.

2.6 Estimación de profundidad

La estimación de pose humana permite conocer la posición de los keypoints en el plano de la imagen, pero no proporciona directamente la distancia entre la cámara y la persona. Para un sistema robótico que debe posicionarse frente a un paciente, esta información 2D no es suficiente. El robot necesita saber si la persona se encuentra demasiado cerca, demasiado lejos o dentro de una zona de trabajo adecuada.

Por este motivo, el proyecto incorpora una fase de estimación de profundidad. Esta fase permite asociar un valor de distancia o proximidad a los landmarks anatómicos externos calculados previamente. En el desarrollo del TFG se estudiaron dos enfoques: el uso de una cámara RGB-D Intel RealSense y la estimación monocular de profundidad mediante Depth Anything 3.

2.6.1 Sensores RGB-D: Intel RealSense

Las cámaras RGB-D combinan una imagen en color con información de profundidad. En el caso de Intel RealSense, la familia D435i incluye un módulo de profundidad y un sensor RGB, lo que permite capturar tanto imagen visual como información espacial de la escena (Intel, 2026). Este tipo de sensor resulta especialmente útil en robótica, ya que proporciona una medida directa de profundidad asociada a la imagen.

En este proyecto, la RealSense se utilizó finalmente como fuente RGB principal para el sistema de percepción. Aunque se evaluó también la profundidad proporcionada por la cámara, las pruebas realizadas mostraron que su uso directo como señal de control no resultaba suficientemente robusto en las condiciones experimentales consideradas.

El principal problema observado no fue que la RealSense no proporcionase profundidad, sino que la lectura local de profundidad en torno a landmarks anatómicos concretos podía variar de forma significativa entre fotogramas consecutivos. Al consultar la profundidad en puntos pequeños de la imagen, como la región tiroidea aproximada o la región prostática aproximada, la señal podía verse afectada por valores no válidos, discontinuidades del mapa de profundidad, pequeñas imprecisiones en la posición del landmark, bordes de la ropa, cambios de postura o zonas con poca información geométrica. Como consecuencia, aunque algunos valores individuales fueran métricamente correctos, la señal no siempre resultaba suficientemente estable para utilizarse directamente en la lógica de movimiento del robot.

Esta variabilidad era especialmente problemática porque el sistema debía transformar la profundidad en acciones discretas como *ACERCAR*, *ALEJAR* o *PARAR*. Pequeños saltos en la profundidad podían provocar cambios bruscos de estado y generar oscilaciones en el comportamiento del robot. Por este motivo, la profundidad de RealSense se mantuvo como referencia experimental para la comparativa métrica, mientras que la arquitectura final utilizó Depth Anything 3 como señal relativa de proximidad, combinada con suavizado temporal y umbrales experimentales.

2.6.2 Estimación monocular de profundidad

La estimación monocular de profundidad busca inferir la estructura espacial de una escena a partir de una imagen RGB. A diferencia de una cámara RGB-D, no requiere un sensor específico

de profundidad, sino que utiliza modelos de visión artificial entrenados para estimar un mapa de profundidad a partir de la información visual.

Este enfoque resulta interesante porque permite obtener una señal de proximidad incluso cuando solo se dispone de una imagen RGB. Sin embargo, también presenta limitaciones. En particular, la escala métrica de la profundidad estimada puede no coincidir exactamente con la distancia real si no se realiza una calibración o validación experimental. Por tanto, en este trabajo la profundidad monocular no se interpreta como una medida absoluta perfecta, sino como una señal relativa que permite clasificar si el robot se encuentra cerca, lejos o en una distancia adecuada respecto a la persona.

2.6.3 Depth Anything 3

Depth Anything 3 es un modelo de estimación de profundidad que permite obtener mapas de profundidad a partir de imágenes o secuencias visuales. El repositorio oficial de ByteDance-Seed proporciona el código y los modelos necesarios para utilizar Depth Anything 3 en tareas de estimación de profundidad (ByteDance-Seed, 2026).

En este TFG, Depth Anything 3 se utiliza para estimar una señal de profundidad asociada a landmarks anatómicos externos. Su función dentro de la arquitectura no es sustituir a un sensor métrico calibrado, sino proporcionar una referencia relativa de proximidad que permita decidir si el robot debe acercarse, alejarse o detenerse frente a la persona.

La Figura 2.2 resume el papel de Depth Anything 3 dentro del sistema. A partir de una imagen RGB, el modelo genera un mapa de profundidad monocular. Posteriormente, el sistema consulta dicho mapa en una ventana local alrededor del landmark anatómico seleccionado y obtiene un valor representativo, como la mediana local. Este valor se interpreta mediante umbrales experimentales para clasificar la situación como *CERCA*, *BIEN_DISTANCIA* o *LEJOS*.




Figura 2.2: Esquema conceptual del uso de Depth Anything 3 como señal relativa de proximidad. Elaborado con apoyo de IA generativa.

Para su integración se tomó como referencia el repositorio oficial del modelo y, además, se utilizó como apoyo el repositorio *cirtesu_da3_mapping*, que integra ROS2 para mapeado 3D usando DA3-Streaming y proporciona indicaciones de configuración, ejecución y uso con imágenes, vídeos y rosbags (Marzà, 2026).

El procedimiento diseñado consiste en detectar primero los keypoints corporales mediante RTMPose, calcular después los landmarks anatómicos de interés y, finalmente, leer la profundidad en una ventana local alrededor del punto seleccionado. Esta lectura local evita depender de un único píxel y reduce el efecto de pequeñas imprecisiones en la posición del landmark. A partir de esta base, el código fue adaptado a las necesidades del proyecto para permitir la consulta de profundidad en puntos anatómicos concretos y su integración dentro de la arquitectura de percepción, decisión y comunicación con ROS2.

Los resultados experimentales mostraron que Depth Anything 3 no debía emplearse como una medida métrica directa sin calibración previa. Sin embargo, sí proporcionó una señal útil como indicador relativo de proximidad. Por ello, en la arquitectura final se utilizaron umbrales experimentales y suavizado temporal para transformar la profundidad estimada en estados funcionales: cerca, distancia adecuada o lejos.

2.7 ROS2 como middleware robótico

ROS2 es un middleware robótico que permite organizar sistemas complejos mediante nodos, mensajes y topics. La documentación oficial describe ROS2 como un sistema basado en comunicación publish/subscribe fuertemente tipada, que permite el intercambio de mensajes entre procesos dentro del grafo ROS (Open Robotics, 2026a). Además, un nodo se define como un participante del grafo ROS que puede comunicarse con otros nodos mediante las librerías cliente correspondientes (Open Robotics, 2026b).

En este proyecto, ROS2 se utiliza como capa de comunicación entre los distintos módulos del sistema. La arquitectura desarrollada publica información como la imagen procesada, los keypoints, los landmarks anatómicos, la orientación de la persona, la profundidad estimada y la acción final generada por la lógica de decisión. Esta estructura permite separar responsabilidades y facilita la depuración del sistema mediante herramientas como *ros2 topic list*, *ros2 topic echo* o la grabación de rosbags.

El uso de ROS2 resulta especialmente adecuado porque el sistema no está formado por un único programa monolítico, sino por varios procesos que deben intercambiar información: captura de imagen, estimación de pose, cálculo de profundidad, publicación de resultados, generación de acciones y comunicación con el robot. Gracias a ROS2, cada módulo puede desarrollarse y probarse de forma más independiente.

2.8 Comunicación entre PC, Android y robot móvil

La arquitectura final del sistema requiere comunicar varios dispositivos con funciones diferentes. El PC actúa como unidad principal de procesamiento, ya que ejecuta RTMPose, Depth Anything 3 y los nodos de ROS2. El dispositivo Android funciona como puente entre el PC y el robot móvil, recibiendo las acciones generadas por el sistema y enviándolas posteriormente al MiniCERNBot mediante Bluetooth.

Esta solución responde a una limitación práctica: el robot utilizado no ejecuta directamente ROS2 ni los modelos de visión artificial. Por ello, el procesamiento pesado se mantiene en el PC, mientras que Android se utiliza como intermediario de comunicación. La cadena funcional puede resumirse de la siguiente manera:

RealSense RGB → RTMPose → landmarks anatómicos → Depth Anything 3 → ROS2 →
Android → Bluetooth → MiniCERNBot

Esta arquitectura distribuida permite validar el comportamiento completo sin necesidad de integrar todos los módulos dentro del propio robot. Además, facilita la separación entre percepción, decisión y actuación, lo que resulta adecuado para una fase experimental de desarrollo.

2.9 Conclusiones del estado del arte

El análisis realizado permite extraer varias conclusiones relevantes para el desarrollo del proyecto. En primer lugar, la estimación de pose humana constituye una herramienta adecuada para obtener una representación estructurada del cuerpo a partir de una imagen RGB. Los keypoints proporcionados por estos modelos pueden utilizarse como base para calcular landmarks anatómicos externos mediante reglas geométricas.

En segundo lugar, la revisión de modelos muestra que RTMPose es la alternativa más adecuada para este TFG, ya que ofrece un buen equilibrio entre precisión, velocidad de inferencia e integración dentro del ecosistema MMPose. YOLO-Pose se considera una opción útil como baseline por su facilidad de uso, ViTPose se mantiene como referencia de alta precisión y OpenPose conserva interés como referencia clásica dentro del área.

Además, el esquema conceptual incluido en la sección dedicada a RTMPose permite visualizar con mayor claridad su papel dentro de la arquitectura desarrollada. Este modelo no proporciona directamente landmarks anatómicos como la región tiroidea o prostática, sino que transforma la imagen RGB de entrada en un conjunto de keypoints corporales. A partir de estos puntos, el sistema calcula posteriormente referencias anatómicas externas adaptadas al objetivo de posicionamiento robótico.

En tercer lugar, la pose 2D por sí sola no permite resolver el problema de posicionamiento del robot, ya que no proporciona información directa sobre la distancia entre la cámara y la persona. Por ello, resulta necesario incorporar estimación de profundidad. En este trabajo se evalúa tanto la profundidad de RealSense como la profundidad monocular proporcionada por Depth Anything 3, empleándose finalmente esta última como señal relativa de proximidad dentro de la lógica de decisión.

El esquema de Depth Anything 3 ayuda a diferenciar su función respecto a RTMPose. Mientras que RTMPose aporta la estructura corporal de la persona mediante keypoints, Depth Anything 3 genera un mapa de profundidad a partir de la imagen RGB. En este proyecto, dicho mapa se consulta en ventanas locales alrededor de los landmarks anatómicos seleccionados y se interpreta mediante umbrales experimentales para clasificar la situación como cerca, distancia adecuada o lejos. Por tanto, su salida no se utiliza como una distancia métrica exacta, sino como una señal relativa útil para la toma de decisiones del robot.

Por último, ROS2 y la comunicación distribuida entre PC, Android y robot móvil permiten integrar los distintos módulos en una arquitectura funcional. Esta combinación hace posible transformar la información visual en acciones de movimiento, avanzando desde una etapa de percepción hacia un sistema experimental de posicionamiento autónomo frente a la persona.

3. Análisis y diseño del sistema

3.1 Requisitos del sistema

El sistema desarrollado en este TFG tiene como finalidad permitir que un robot móvil se posicione de forma autónoma frente a una persona utilizando información visual. Para ello, debe detectar referencias anatómicas externas aproximadas, estimar una señal de distancia relativa y transformar dicha información en acciones de movimiento.

Desde el punto de vista del diseño, el sistema se plantea como una etapa previa a una posible medición radiológica localizada. Por este motivo, no solo debe detectar landmarks anatómicos externos, sino también comprobar que la persona se encuentra en una orientación adecuada. En el contexto previsto, las mediciones se realizarían con el paciente situado de frente, por lo que la frontalidad se convierte en una condición necesaria para considerar válida la información obtenida.

A partir de este planteamiento, los requisitos del sistema se dividen en requisitos funcionales y requisitos no funcionales.

3.1.1 Requisitos funcionales

Los requisitos funcionales describen las acciones que el sistema debe ser capaz de realizar para cumplir los objetivos del proyecto. En este caso, los principales requisitos funcionales son los siguientes:

- Capturar imágenes en tiempo real de la persona situada frente al robot.
- Detectar la pose humana en la imagen mediante un modelo de estimación de pose.
- Obtener keypoints corporales relevantes, como hombros, caderas, nariz y ojos.
- Calcular landmarks anatómicos externos aproximados a partir de los keypoints detectados.
- Identificar referencias anatómicas relacionadas con la zona cervical, tiroidea, pélvica y prostática.

- Determinar si la persona se encuentra en una orientación frontal válida, ya que la aplicación prevista requiere que las futuras mediciones radiológicas se realicen con el paciente situado de frente al sistema.
- Estimar una señal de profundidad asociada a los landmarks anatómicos seleccionados.
- Suavizar temporalmente la señal de profundidad para reducir oscilaciones entre fotogramas consecutivos.
- Clasificar la distancia relativa entre el robot y la persona en estados funcionales, como cerca, distancia adecuada o lejos.
- Determinar si el landmark seleccionado está centrado horizontalmente en la imagen.
- Generar una acción de movimiento en función de la distancia y del centrado horizontal.
- Publicar en ROS2 la información relevante del sistema, incluyendo landmarks, orientación, profundidad y acción final.
- Comunicar la acción generada desde ROS2 hasta una aplicación Android.
- Enviar desde Android comandos de movimiento al robot móvil mediante Bluetooth.
- Detener el robot en caso de pérdida de medición, ausencia de landmarks válidos o falta de comunicación.

3.1.2 Requisitos no funcionales

Los requisitos no funcionales describen las condiciones de calidad, robustez y organización que debe cumplir el sistema. En este proyecto, resultan especialmente importantes debido a que la arquitectura combina visión artificial, comunicación distribuida y movimiento robótico.

- **Modularidad:** el sistema debe estar dividido en módulos independientes, de forma que la captura de imagen, la detección de pose, la estimación de profundidad, la publicación en ROS2 y la comunicación con el robot puedan modificarse o sustituirse sin rehacer toda la arquitectura.
- **Funcionamiento en tiempo real:** la arquitectura debe procesar imágenes de forma continua y generar acciones de movimiento con una latencia suficientemente baja para permitir una respuesta útil del robot.
- **Robustez:** el sistema debe evitar tomar decisiones a partir de mediciones poco fiables, por ejemplo cuando la persona no está de frente, cuando no se detectan landmarks válidos o cuando la señal de profundidad presenta variaciones bruscas.
- **Seguridad:** ante situaciones de incertidumbre, pérdida de señal o ausencia de medición válida, la acción por defecto debe ser detener el robot.
- **Escalabilidad:** la arquitectura debe permitir añadir en el futuro nuevos sensores, nuevos landmarks anatómicos o un módulo de medición radiológica.
- **Interpretabilidad:** el sistema debe mostrar información comprensible sobre el estado actual, como orientación detectada, landmark utilizado, profundidad estimada y acción generada.
- **Compatibilidad:** dado que RTMPose, Depth Anything 3 y ROS2 presentan dependencias distintas, el diseño debe permitir separar entornos de ejecución y comunicar los módulos mediante mecanismos intermedios.

3.2 Arquitectura general del sistema

La arquitectura del sistema desarrollado se organiza en varios módulos que cooperan para transformar la información visual capturada por el robot en acciones de movimiento. De forma general, el sistema parte de una imagen RGB obtenida mediante la cámara Intel RealSense, estima la pose humana con RTMPose, calcula landmarks anatómicos externos, obtiene una señal de profundidad relativa mediante Depth Anything 3 y, a partir de dicha información, genera decisiones de posicionamiento que se envían al robot a través de ROS2 y de un puente de comunicación con Android.

La Figura 3.1 muestra una visión global del funcionamiento del sistema y de la relación entre sus principales módulos. Además, recrea el escenario de aplicación previsto, en el que el robot móvil se aproxima frontalmente al paciente y utiliza la información visual para decidir su movimiento.




Figura 3.1: Arquitectura general del sistema propuesto, incluyendo percepción, estimación de profundidad, toma de decisiones, comunicación y ejecución sobre el robot. Elaborado con apoyo de IA generativa.

Como puede observarse en la figura, el sistema se divide en tres bloques principales. En primer lugar, el bloque de procesamiento y percepción recibe la imagen RGB capturada por la cámara y aplica RTMPose para obtener los keypoints corporales. A partir de ellos se calculan landmarks anatómicos externos, como la base cervical, la región tiroidea aproximada, el centro pélvico y la región prostática aproximada. Paralelamente, la imagen se procesa mediante Depth Anything 3 para generar un mapa de profundidad, del cual se extrae una lectura local asociada al landmark anatómico seleccionado.

En segundo lugar, el sistema valida la orientación del paciente y clasifica la señal de profundidad relativa tras aplicar un suavizado temporal. Esta información alimenta la lógica de decisión, que

determina la acción que debe realizar el robot, por ejemplo acercarse, alejarse, detenerse o corregir lateralmente su posición. Esta etapa es fundamental porque permite pasar de una salida visual a una decisión funcional de movimiento.

Por último, el bloque de comunicación y ejecución se encarga de publicar la información en ROS2, transmitir la acción al dispositivo Android y reenviarla al MiniCERNBot mediante Bluetooth. De esta forma, la decisión calculada por el sistema se traduce en movimiento real del robot, cerrando la cadena de percepción, decisión y actuación.

La arquitectura se divide en cinco módulos principales:

- Módulo de percepción.
- Módulo de landmarks anatómicos.
- Módulo de profundidad.
- Módulo de decisión.
- Módulo de comunicación y actuación.

Esta división permite separar las responsabilidades del sistema y facilita tanto la depuración como futuras ampliaciones. A partir de esta visión global, en los apartados siguientes se describe con mayor detalle el diseño de cada uno de los módulos que componen la arquitectura propuesta.

3.3 Diseño del módulo de percepción

El módulo de percepción constituye la primera etapa del sistema. Su función es adquirir la imagen de entrada, detectar la pose humana y proporcionar los puntos corporales necesarios para calcular los landmarks anatómicos externos.

3.3.1 Captura de imagen

La captura de imagen se realiza mediante una cámara Intel RealSense. Aunque este tipo de cámara puede proporcionar tanto imagen RGB como profundidad, en la arquitectura final se utiliza principalmente como cámara RGB. Esta decisión permite disponer de una imagen estable para aplicar RTMPose y Depth Anything 3, manteniendo la profundidad de RealSense como referencia experimental para comparativas.

La imagen capturada debe cumplir varias condiciones para ser útil dentro del sistema. En primer lugar, la persona debe aparecer dentro del campo de visión de la cámara. En segundo lugar, las regiones corporales necesarias para calcular los landmarks deben ser visibles de forma suficiente. Por último, la imagen debe tener una resolución adecuada para que el modelo de pose pueda detectar keypoints con confianza razonable.

En el diseño del sistema, la cámara se sitúa en el robot o en una posición equivalente a la perspectiva del robot, de forma que la información visual obtenida pueda utilizarse para tomar decisiones de movimiento.

3.3.2 Detección de pose humana

La detección de pose humana se realiza mediante RTMPose. El modelo recibe una imagen RGB y devuelve un conjunto de keypoints corporales con sus coordenadas y niveles de confianza. Entre los keypoints de mayor interés para este proyecto se encuentran los hombros, las caderas, la nariz y los ojos.

Estos puntos permiten construir una representación del esqueleto externo de la persona. Sin embargo, el sistema no utiliza directamente todos los keypoints para la toma de decisiones. En

su lugar, selecciona aquellos que son necesarios para calcular las referencias anatómicas externas definidas en el proyecto.

La salida del modelo debe ser filtrada en función de la confianza de cada keypoint. Si un punto tiene una confianza demasiado baja, no debe utilizarse para calcular un landmark anatómico, ya que podría generar una referencia errónea. Por ello, el diseño contempla umbrales mínimos de confianza para aceptar o descartar puntos corporales.

3.3.3 Obtención de landmarks anatómicos externos

Los landmarks anatómicos externos no son detectados directamente por RTMPose, sino que se calculan mediante postprocesado geométrico a partir de los keypoints corporales. Esta etapa permite adaptar la salida general del modelo de pose a las necesidades específicas del proyecto.

El proceso general es el siguiente:

1. Detectar los keypoints corporales mediante RTMPose.
2. Comprobar la confianza de los puntos necesarios.
3. Calcular referencias anatómicas derivadas mediante relaciones geométricas.
4. Validar si los landmarks obtenidos pueden utilizarse en la medición.
5. Publicar o almacenar los landmarks para las siguientes etapas del sistema.

Este enfoque permite obtener referencias anatómicas externas sin entrenar un modelo específico. No obstante, debe recordarse que estos landmarks son aproximaciones geométricas, no localizaciones clínicas exactas de órganos internos.

Aunque el sistema calcula varias referencias auxiliares, los landmarks principales para la aplicación planteada son la región tiroidea aproximada y la región prostática aproximada. Estas dos regiones son las que se utilizan como referencias externas para orientar el posicionamiento del robot frente a las zonas corporales de interés. La base cervical y el centro pélvico se emplean como puntos intermedios de cálculo, pero no constituyen por sí mismos el objetivo final de posicionamiento.

La Figura 3.2 muestra un ejemplo de los dos landmarks anatómicos externos principales calculados a partir de los keypoints corporales detectados por RTMPose. En la imagen se observa, por un lado, la región tiroidea aproximada situada en la zona cervical y, por otro, la región prostática aproximada situada en la zona pélvica. Estos puntos no representan órganos internos exactos, sino referencias externas útiles para el posicionamiento del robot.



Figura 3.2: Representación visual de los landmarks anatómicos externos principales utilizados por el sistema: (a) región tiroidea aproximada y (b) región prostática aproximada.

3.4 Definición de landmarks anatómicos

En este trabajo no se pretende localizar directamente órganos internos, ya que estos no son visibles en la imagen RGB capturada por la cámara. En su lugar, se definen landmarks anatómicos externos a partir de los keypoints corporales detectados por RTMPose. Estas referencias se calculan mediante relaciones geométricas entre puntos visibles del cuerpo y se utilizan como aproximaciones funcionales para el posicionamiento del robot.

Los landmarks anatómicos definidos en el sistema tienen como objetivo proporcionar referencias espaciales útiles para posicionar el robot frente a regiones corporales de interés. En este TFG se consideran dos landmarks principales de aplicación: la región tiroidea aproximada y la región prostática aproximada. Para calcularlos, el sistema utiliza dos referencias auxiliares: la base cervical y el centro pélvico.

De este modo, la base cervical permite construir una referencia externa en la zona superior del tronco para estimar la región tiroidea aproximada, mientras que el centro pélvico permite construir una referencia externa en la zona inferior del tronco para estimar la región prostática aproximada. Esta distinción es importante, ya que no todos los puntos calculados tienen el mismo papel dentro del sistema: algunos actúan como puntos auxiliares y otros como landmarks finales de interés para el posicionamiento robótico.

3.4.1 Base cervical

La base cervical, denominada en el sistema como *neck_base*, se calcula como el punto medio entre el hombro izquierdo y el hombro derecho. Esta referencia queda situada aproximadamente en la parte inferior del cuello y centrada respecto al tronco superior. Si las coordenadas de ambos hombros son:

$$S_L = (x_{S_L}, y_{S_L}), \quad S_R = (x_{S_R}, y_{S_R}) \quad (3.1)$$

la base cervical se calcula como:

$$neck_base = \left(\frac{x_{S_L} + x_{S_R}}{2}, \frac{y_{S_L} + y_{S_R}}{2} \right) \quad (3.2)$$

Este punto resulta útil porque se encuentra en una zona relativamente estable del cuerpo y depende de keypoints generalmente visibles en una persona situada de frente. En el sistema desarrollado, la base cervical actúa principalmente como referencia auxiliar para calcular la región tiroidea aproximada. Además, durante las pruebas de profundidad, mostró un comportamiento prometedor como referencia de distancia relativa.

3.4.2 Región tiroidea aproximada

La región tiroidea aproximada se calcula a partir de la base cervical y la nariz. La idea es estimar un punto situado en la zona anterior del cuello, entre la base cervical y la cabeza. Como se observa en la Figura 3.2, este landmark se representa sobre la zona cervical y constituye una de las referencias principales del sistema.

Si la nariz se representa como:

$$N = (x_N, y_N) \quad (3.3)$$

la región tiroidea aproximada puede calcularse mediante una interpolación entre la base cervical y la nariz:

$$thyroid = neck_base + \alpha(N - neck_base) \quad (3.4)$$

donde α es un factor experimental que determina la posición relativa del punto sobre el segmento que une la base cervical con la nariz.

Este landmark no representa la localización exacta de la glándula tiroides, ya que dicha estructura no es visible mediante una cámara RGB. Su finalidad es proporcionar una referencia externa aproximada en la zona cervical, útil para orientar el posicionamiento del robot y una posible medición radiológica futura alrededor de esa región.

3.4.3 Centro pélvico

El centro pélvico se calcula como el punto medio entre la cadera izquierda y la cadera derecha. Esta referencia se obtiene a partir de la geometría definida por las caderas y proporciona un punto central en la región pélvica.

Si las coordenadas de ambas caderas son:

$$H_L = (x_{H_L}, y_{H_L}), \quad H_R = (x_{H_R}, y_{H_R}) \quad (3.5)$$

el centro pélvico se obtiene como:

$$pelvis = \left(\frac{x_{H_L} + x_{H_R}}{2}, \frac{y_{H_L} + y_{H_R}}{2} \right) \quad (3.6)$$

Este punto permite obtener una referencia estable en la zona media-inferior del tronco. Su utilidad principal dentro del sistema es servir como base para calcular la región prostática aproximada. Por tanto, al igual que la base cervical, se trata de una referencia auxiliar dentro del proceso de estimación de landmarks anatómicos externos.

3.4.4 Región prostática aproximada

La región prostática aproximada se calcula a partir del centro pélvico y de la anchura entre caderas. Como se observa en la Figura 3.2, este landmark se representa sobre la zona pélvica y constituye la segunda referencia principal de aplicación del sistema. Al igual que en el caso tiroideo, no se pretende localizar un órgano interno con precisión clínica, sino obtener una referencia externa útil para el posicionamiento del robot frente a una región anatómica de interés.

La anchura de caderas se puede calcular como:

$$w_{hips} = |x_{H_R} - x_{H_L}| \quad (3.7)$$

A partir de esa anchura, la región prostática aproximada puede estimarse mediante un desplazamiento vertical:

$$prostate = (x_{pelvis}, y_{pelvis} + \beta w_{hips}) \quad (3.8)$$

donde β es un factor experimental que controla el desplazamiento respecto al centro pélvico. En el sistema de coordenadas de imagen, el eje vertical aumenta hacia abajo, por lo que el desplazamiento positivo en y sitúa el punto en una región inferior.

Este landmark debe entenderse como una referencia externa aproximada asociada a la región prostática, no como una localización anatómica exacta. Su utilidad se centra en orientar el posicionamiento del robot y delimitar una zona externa de interés para posibles mediciones posteriores.

3.5 Validación de orientación del paciente

La validación de la orientación de la persona es una parte fundamental del sistema, ya que los landmarks anatómicos externos solo resultan útiles si la postura observada es coherente con la medición prevista. En el contexto de aplicación considerado, las futuras mediciones radiológicas localizadas se realizarían con el paciente situado de frente al sistema. Por tanto, la frontalidad no se incorpora como una condición arbitraria, sino como un requisito funcional de la aplicación hospitalaria planteada.

Esta restricción se debe a que las regiones anatómicas de interés consideradas en este TFG, como la zona tiroidea y la región prostática, se estiman a partir de referencias externas observadas en una vista frontal del cuerpo. Si la persona se encuentra de lado, de espaldas o parcialmente girada, las relaciones geométricas entre keypoints cambian y los landmarks calculados pueden dejar de representar correctamente la zona externa que se desea utilizar para el posicionamiento del robot. En esas condiciones, el sistema podría seguir detectando una pose humana, pero la información obtenida no sería adecuada para orientar una posible medición posterior.

En un escenario hospitalario real, se asumiría que el personal sanitario indicaría al paciente que se colocara frontalmente antes de iniciar la medición. Por ello, el objetivo del sistema no es adaptarse a cualquier orientación corporal posible, sino comprobar que se cumple la postura esperada para la tarea. La validación de frontalidad actúa así como un filtro previo que permite decidir si la información anatómica y de profundidad puede utilizarse o si, por el contrario, el robot debe mantenerse detenido.

3.5.1 Detección de frontalidad

La detección de frontalidad se basa en el análisis de keypoints faciales y corporales. Esta comprobación es necesaria porque el sistema solo debe permitir la estimación de landmarks y la

generación de acciones de movimiento cuando el paciente se encuentra en una posición compatible con la aplicación prevista, es decir, situado de frente al robot.

En una primera aproximación podría considerarse suficiente comprobar la presencia de la nariz y ambos ojos. Sin embargo, durante el desarrollo se observó que esta estrategia podía resultar ambigua, ya que el modelo puede detectar keypoints faciales incluso cuando la persona no se encuentra completamente de frente. Por este motivo, el diseño contempla una validación más restrictiva basada en la coherencia geométrica de los puntos detectados.

En una vista frontal, ambos ojos deberían aparecer a una altura similar, la nariz debería situarse aproximadamente entre ellos y el conjunto de la cara debería mantener una posición coherente respecto al eje del tronco definido por los hombros. Si estas relaciones no se cumplen, aunque existan keypoints faciales, la orientación no se considera suficientemente fiable para permitir la medición.

Inicialmente puede parecer útil utilizar también las orejas para estimar la orientación. Sin embargo, en la práctica estos puntos pueden resultar ambiguos, ya que pueden detectarse incluso cuando la persona no está completamente de frente. Por este motivo, el diseño prioriza la nariz y los ojos como indicadores principales de frontalidad, junto con la coherencia del eje corporal.

La orientación detectada puede clasificarse de forma simplificada como:

- **Frontal:** la persona presenta una disposición adecuada para calcular landmarks, estimar profundidad y orientar una posible medición posterior.
- **No frontal:** la orientación no permite asegurar que los landmarks calculados sean fiables para la aplicación prevista.
- **No válida:** no se detectan suficientes puntos faciales o corporales para realizar la medición con garantías.

3.5.2 Condiciones para permitir la medición

El sistema solo debe utilizar la profundidad y generar acciones de movimiento cuando se cumplen unas condiciones mínimas de fiabilidad. Estas condiciones son necesarias para evitar que el robot actúe a partir de referencias anatómicas mal calculadas o de una postura no válida para la aplicación prevista.

En el escenario considerado, la medición solo se considera válida cuando el paciente está situado de frente al sistema. Esta restricción responde a la forma en que se plantea la aplicación hospitalaria: antes de realizar una medición localizada, el paciente sería colocado o instruido para mantenerse frontal respecto al robot. Por tanto, el sistema no intenta adaptar la medición a cualquier orientación corporal, sino comprobar que se cumple la orientación esperada antes de continuar.

De forma general, la medición se considera permitida cuando:

- La persona está detectada en la imagen.
- La orientación de la persona es frontal o suficientemente compatible con una vista frontal.
- Los keypoints necesarios para calcular el landmark seleccionado tienen una confianza suficiente.
- El landmark anatómico externo se ha calculado correctamente.
- Existe una profundidad válida asociada al landmark.

Si alguna de estas condiciones no se cumple, el sistema considera que no existe una medición fiable. En ese caso, la acción segura es detener el robot o mantenerlo parado hasta recuperar una

situación válida. De este modo, la validación de orientación actúa como un filtro previo que impide que el robot tome decisiones de posicionamiento basadas en una postura no adecuada para la futura medición radiológica.

3.6 Diseño del módulo de profundidad

El módulo de profundidad tiene como objetivo asociar una señal de distancia relativa a los landmarks anatómicos externos. Para ello, se utiliza Depth Anything 3 sobre la imagen RGB y se consulta la profundidad en torno al punto seleccionado.

Debe tenerse en cuenta que la profundidad proporcionada por Depth Anything 3 no se utiliza en este diseño como una medida métrica absoluta de distancia. Al tratarse de un modelo de profundidad monocular, la salida se obtiene a partir de la imagen RGB y no mediante una medición física directa con un sensor de profundidad. Por este motivo, aunque el modelo genera un valor numérico de profundidad, este no se interpreta directamente como una distancia exacta en metros entre el robot y el paciente sin un proceso adicional de calibración.

En este trabajo, la salida de Depth Anything 3 se emplea como una señal relativa de proximidad. Es decir, el sistema utiliza la variación de esa señal para determinar si la persona se encuentra más cerca, más lejos o dentro de un rango considerado adecuado. Por tanto, el valor de profundidad se utiliza como una métrica interna para la toma de decisiones del robot, no como una medición física exacta de la distancia real.

3.6.1 Lectura de profundidad en landmarks

Depth Anything 3 genera un mapa de profundidad asociado a la imagen RGB de entrada. Este mapa puede entenderse como una matriz en la que cada píxel contiene un valor estimado de profundidad. A partir de los landmarks anatómicos calculados previamente, el sistema consulta dicho mapa en la zona correspondiente al punto de interés.

La profundidad no se lee en un único píxel exacto, ya que pequeños errores en la detección del landmark podrían provocar valores inestables. En su lugar, se utiliza una ventana local alrededor del punto. Esta ventana permite obtener una medida más robusta de la profundidad en la zona cercana al landmark.

Si el landmark seleccionado se representa mediante las coordenadas:

$$p_l = (x_l, y_l) \quad (3.9)$$

y el mapa de profundidad generado por Depth Anything 3 se denota como D , la profundidad asociada al landmark se obtiene a partir de una ventana local $W(p_l)$ alrededor del punto:

$$z_l = \text{median}\{D(u, v) \mid (u, v) \in W(p_l)\} \quad (3.10)$$

donde z_l representa el valor de profundidad estimado para el landmark seleccionado. En este caso se utiliza la mediana, y no la media, porque la ventana local de profundidad puede contener valores no representativos del landmark. Esto puede ocurrir cuando la ventana incluye píxeles de fondo, bordes entre el cuerpo y la ropa, discontinuidades del mapa de profundidad, valores no válidos o pequeñas variaciones en la posición del landmark entre fotogramas. En estas condiciones, la señal no puede asumirse como un ruido gaussiano uniforme, sino que puede incluir valores atípicos o extremos. La mediana resulta más robusta frente a estos valores y permite obtener una lectura local más estable para la lógica de decisión del robot.

El procedimiento general es el siguiente:

1. Seleccionar el landmark anatómico principal.
2. Obtener sus coordenadas en la imagen.
3. Consultar el mapa de profundidad generado por Depth Anything 3.
4. Extraer una ventana local alrededor del punto.
5. Calcular un valor representativo de profundidad mediante la mediana de los valores válidos de la ventana.

Este diseño reduce el impacto de valores aislados y mejora la estabilidad de la señal. Además, permite aplicar el mismo procedimiento a distintos landmarks, como la región tiroidea aproximada o la región prostática aproximada.

3.6.2 Suavizado temporal

La profundidad estimada puede variar entre fotogramas consecutivos aunque la persona y el robot permanezcan prácticamente quietos. Estas oscilaciones pueden deberse al propio modelo de estimación de profundidad, a pequeñas variaciones en la detección del landmark, a cambios mínimos en la imagen o a valores puntuales no representativos.

Para evitar que el robot reaccione de forma brusca ante estas variaciones, el diseño incorpora un suavizado temporal. Este suavizado se basa en mantener una ventana de los últimos valores válidos de profundidad y calcular la mediana temporal. De este modo, se reduce la influencia de medidas puntuales anómalas que podrían alterar la decisión de movimiento del robot.

Si se dispone de los últimos n valores válidos de profundidad estimada para un landmark, la señal suavizada puede expresarse como:

$$\bar{z}_l = \text{median}(z_{l,t-n+1}, z_{l,t-n+2}, \dots, z_{l,t}) \quad (3.11)$$

donde $\bar{z}_l$ representa la profundidad suavizada utilizada por la lógica de decisión.

La elección de la mediana en el suavizado temporal responde al mismo criterio de robustez aplicado en la lectura local de profundidad. Durante las pruebas se observaron variaciones puntuales entre fotogramas consecutivos, incluso cuando la persona y el robot permanecían prácticamente quietos. Un único valor extremo podía alterar la clasificación de distancia y provocar cambios no deseados en la acción generada. Al utilizar la mediana de los últimos valores válidos, se reduce la influencia de esos saltos puntuales y se obtiene una señal más estable para decidir si el robot debe acercarse, alejarse o detenerse.

La señal suavizada permite obtener una estimación más estable que la profundidad instantánea. Por ello, la lógica de decisión del robot se basa preferentemente en la profundidad suavizada y no en el valor bruto de un único frame.

3.6.3 Clasificación de distancia

La profundidad obtenida mediante Depth Anything 3 se utiliza como una señal relativa de proximidad. Por tanto, no se interpreta como una distancia métrica exacta, sino como un valor que permite clasificar la situación del robot respecto a la persona.

Por este motivo, la lógica de distancia se plantea como una clasificación por estados y no como un control basado en una distancia métrica exacta. Los valores de profundidad se interpretan mediante umbrales definidos experimentalmente, de forma que el sistema pueda tomar decisiones funcionales aunque la escala de Depth Anything 3 no coincida perfectamente con la distancia real. Esta aproximación resulta suficiente para el objetivo del proyecto, ya que el robot no necesita

conocer una distancia física exacta, sino saber cómo debe actuar para colocarse en una posición adecuada.

El sistema define tres estados principales:

- **CERCA:** la persona se encuentra demasiado próxima al robot.
- **BIEN_DISTANCIA:** la persona se encuentra dentro del rango de trabajo considerado adecuado.
- **LEJOS:** la persona se encuentra demasiado alejada del robot.

Los umbrales utilizados para esta clasificación se definen de forma experimental. En la versión final del sistema se emplea un rango de distancia adecuada delimitado por un umbral inferior y un umbral superior. Si la profundidad suavizada queda por debajo del umbral inferior, el sistema interpreta que la persona está demasiado cerca. Si queda por encima del umbral superior, interpreta que está lejos. Si se encuentra dentro del rango, se considera que el robot está a una distancia adecuada.

La clasificación puede expresarse de forma general como:

$$\text{estado} = \begin{cases} \text{CERCA}, & \bar{z}_l < T_{\min} \\ \text{BIEN_DISTANCIA}, & T_{\min} \leq \bar{z}_l \leq T_{\max} \\ \text{LEJOS}, & \bar{z}_l > T_{\max} \end{cases} \quad (3.12)$$

donde $T_{\min}$ y $T_{\max}$ representan los umbrales inferior y superior del rango de distancia considerado adecuado. Esta clasificación permite transformar la profundidad estimada por Depth Anything 3 en una decisión funcional para el robot.

3.6.4 Criterios para la elección de umbrales de distancia

La clasificación de la distancia se basa en umbrales experimentales aplicados sobre la profundidad relativa obtenida a partir de Depth Anything 3. Estos umbrales permiten transformar una señal continua de profundidad en estados funcionales simples, como *CERCA*, *BIEN_DISTANCIA* o *LEJOS*. Esta discretización resulta necesaria porque el robot no necesita conocer una distancia métrica exacta para tomar una decisión básica de posicionamiento, sino determinar si debe acercarse, alejarse o detenerse.

Los umbrales se seleccionaron de forma experimental a partir de pruebas realizadas en el entorno de trabajo. Para ello, se colocó a la persona en distintas posiciones relativas respecto a la cámara y se observaron los valores de profundidad estimados en el landmark seleccionado. A partir de estos valores se identificaron rangos asociados a tres situaciones funcionales: una distancia demasiado cercana, una distancia considerada adecuada para la aplicación planteada y una distancia excesiva. De este modo, los umbrales no se definieron como medidas clínicas o métricas absolutas, sino como límites prácticos para la lógica de movimiento del robot.

El criterio seguido fue elegir valores que separasen de forma clara los tres estados funcionales y que, al mismo tiempo, evitasen cambios constantes de estado ante pequeñas variaciones de la señal. Por este motivo, la profundidad utilizada por la lógica de decisión no corresponde al valor bruto de un único píxel ni de un único fotograma, sino a una señal procesada mediante lectura local en ventana y suavizado temporal. Esta estrategia reduce el efecto de valores aislados, pequeñas oscilaciones del modelo de profundidad y variaciones puntuales en la detección del landmark.

No obstante, es importante señalar que estos umbrales no pueden considerarse completamente robustos ante cualquier cambio de escenario. Depth Anything 3 proporciona una estimación de profundidad monocular que, sin una calibración específica, debe interpretarse como una señal

relativa. Por tanto, cambios importantes en la iluminación, el fondo, la ropa del paciente, la cámara utilizada o la disposición de la escena podrían modificar la distribución de valores obtenida y requerir una nueva calibración experimental de los umbrales.

Para mejorar la robustez del sistema se incorporan varias restricciones adicionales: la validación de frontalidad del paciente, la comprobación de landmarks válidos, la lectura local mediante mediana y el suavizado temporal de la señal. Estas medidas no eliminan por completo la dependencia del escenario, pero reducen la probabilidad de que una medición puntual o inestable provoque una acción incorrecta del robot.

En consecuencia, los umbrales empleados deben entenderse como parámetros experimentales válidos para el entorno de pruebas considerado. En una futura implementación hospitalaria, sería necesario realizar una fase de calibración específica en el entorno real de uso, idealmente comparando la profundidad estimada con medidas de referencia o con un sensor métrico calibrado. Esta calibración permitiría ajustar los umbrales a las condiciones reales de iluminación, cámara, distancia de trabajo y configuración espacial del sistema.

3.7 Diseño del módulo de decisión

El módulo de decisión transforma la información de profundidad y centrado en una acción final para el robot. Esta acción se publica posteriormente en ROS2 y se envía a la aplicación Android para su ejecución sobre el MiniCERNBot.

3.7.1 Acciones de acercamiento y alejamiento

La primera parte de la lógica de decisión se basa en la distancia relativa entre el robot y la persona. Según el estado de distancia, se genera una acción básica:

Tabla 3.1: Acciones básicas en función de la distancia

Estado de distancia	Situación interpretada	Acción básica
CERCA	La persona está demasiado próxima	ALEJAR
BIEN_DISTANCIA	La persona está en el rango adecuado	PARAR
LEJOS	La persona está demasiado alejada	ACERCAR
SIN_MEDIDA	No existe medida fiable	PARAR

Esta lógica permite regular la distancia longitudinal entre el robot y la persona. Sin embargo, para situarse correctamente frente a ella, también es necesario corregir la posición lateral.

3.7.2 Centrado horizontal del robot

Además de la distancia, el sistema analiza el centrado horizontal del landmark seleccionado en la imagen. Para ello, se compara la coordenada horizontal del landmark con el centro de la imagen.

Si la imagen tiene una anchura W , el centro horizontal se define como:

$$x_c = \frac{W}{2} \quad (3.13)$$

Si la coordenada horizontal del landmark es x_l , el error de centrado se calcula como:

$$e_x = x_l - x_c \quad (3.14)$$

A partir de este error, se definen tres estados:

- **IZQUIERDA:** el landmark aparece desplazado hacia la izquierda de la imagen.
- **CENTRADO:** el landmark se encuentra dentro de una tolerancia respecto al centro.
- **DERECHA:** el landmark aparece desplazado hacia la derecha de la imagen.

La tolerancia de centrado evita que el robot realice correcciones laterales por desviaciones pequeñas. Si el error horizontal se encuentra dentro del margen permitido, el sistema considera que el robot está suficientemente alineado.

3.7.3 Combinación de acciones

Para obtener la acción final del robot, el sistema combina la acción asociada a la distancia con la acción asociada al centrado horizontal. Esta combinación permite que el robot pueda acercarse o alejarse mientras corrige lateralmente su posición.

La Tabla 3.2 resume la lógica de combinación.

Tabla 3.2: Combinación de acciones de distancia y centrado

Estado de distancia	Estado horizontal	Acción final
BIEN_DISTANCIA	CENTRADO	PARAR
BIEN_DISTANCIA	IZQUIERDA	IZQUIERDA
BIEN_DISTANCIA	DERECHA	DERECHA
LEJOS	CENTRADO	ACERCAR
LEJOS	IZQUIERDA	ACERCAR_IZQUIERDA
LEJOS	DERECHA	ACERCAR_DERECHA
CERCA	CENTRADO	ALEJAR
CERCA	IZQUIERDA	ALEJAR_IZQUIERDA
CERCA	DERECHA	ALEJAR_DERECHA
SIN_MEDIDA	Cualquiera	PARAR

Esta lógica resulta especialmente importante porque permite corregir situaciones en las que la distancia es adecuada, pero el robot no está centrado frente a la persona. En ese caso, la acción no debe ser simplemente *PARAR*, sino un desplazamiento lateral hasta alcanzar una posición más alineada.

3.7.4 Bloqueo de posición alcanzada

Durante las pruebas se observó que pequeñas fluctuaciones en la profundidad estimada podían provocar cambios frecuentes en la acción generada. Por ejemplo, el sistema podía alternar entre *PARAR*, *ACERCAR* y *ALEJAR* aunque la persona y el robot estuvieran prácticamente quietos.

Para evitar este comportamiento, el diseño incorpora un bloqueo de posición alcanzada. Cuando el robot se encuentra en una situación considerada válida, es decir, con distancia adecuada y centrado horizontal, el sistema entra en un estado de bloqueo. En este estado, la acción se mantiene como *PARAR* y se ignoran pequeñas variaciones de profundidad o centrado.

El sistema solo sale del bloqueo cuando se detecta un cambio suficientemente significativo durante varios ciclos consecutivos. Por ejemplo, si la profundidad indica de forma persistente que la persona se ha alejado, el robot vuelve a activar la acción de acercamiento. Del mismo modo, si el landmark se desplaza lateralmente más allá de un margen definido, se permite una nueva corrección lateral.

Este mecanismo introduce memoria en la lógica de decisión y evita que el robot oscile continuamente por ruido en la señal visual.

3.8 Diseño de la comunicación

El sistema requiere comunicar varios procesos y dispositivos. Por un lado, los módulos de visión y profundidad se ejecutan en el ordenador. Por otro, el robot MiniCERNBot recibe comandos a través de una aplicación Android. Para conectar todas las partes se utiliza una arquitectura distribuida basada en ROS2, TCP/WiFi y Bluetooth.

3.8.1 Publicación de información en ROS2

ROS2 actúa como capa intermedia de comunicación entre los módulos del sistema. El diseño contempla la publicación de información visual, anatómica y de decisión mediante topics. Entre los datos publicados se incluyen:

- Imagen procesada.
- Landmark de la región tiroidea aproximada.
- Landmark de la región prostática aproximada.
- Keypoints corporales.
- Landmarks anatómicos completos.
- Orientación de la persona.
- Indicador de medición permitida.
- Profundidad suavizada.
- Estado de distancia.
- Acción final generada.

Esta publicación permite visualizar, depurar y grabar el comportamiento del sistema mediante herramientas propias de ROS2. Además, facilita que otros nodos puedan reutilizar la información en futuras ampliaciones del proyecto.

3.8.2 Puente ROS2–Android

El robot MiniCERNBot no ejecuta directamente ROS2, por lo que es necesario un puente intermedio entre el sistema de decisión y la aplicación Android. Este puente se suscribe al topic de acción final publicado en ROS2 y envía dicha acción a Android mediante una conexión TCP sobre WiFi.

El diseño de este puente permite desacoplar el procesamiento principal del sistema de la comunicación con el robot. De esta forma, el PC se encarga de ejecutar los modelos de visión artificial y ROS2, mientras que Android actúa como intermediario para transmitir las órdenes al robot.

3.8.3 Comunicación Android–MiniCERNBot

La comunicación entre la aplicación Android y el MiniCERNBot se realiza mediante Bluetooth. La aplicación recibe acciones simbólicas desde el PC, como *ACERCAR*, *ALEJAR*, *PARAR*, *IZQUIERDA* o *DERECHA*, y las traduce a comandos simples que el robot puede interpretar.

La Tabla 3.3 resume la correspondencia conceptual entre acciones y movimientos.

Tabla 3.3: Correspondencia entre acciones del sistema y movimiento del robot

Acción del sistema	Movimiento asociado
ACERCAR	Avance del robot hacia la persona
ALEJAR	Retroceso del robot respecto a la persona
PARAR	Detención del robot
IZQUIERDA	Desplazamiento lateral hacia la izquierda
DERECHA	Desplazamiento lateral hacia la derecha
ACERCAR_IZQUIERDA / ACERCAR_DERECHA	Avance combinado con corrección lateral
ALEJAR_IZQUIERDA / ALEJAR_DERECHA	Retroceso combinado con corrección lateral

En caso de pérdida de medición o de comunicación, la acción segura es detener el robot. Este comportamiento es fundamental para evitar movimientos no deseados cuando el sistema no dispone de información fiable.

3.9 Diseño de interfaces y visualización

El sistema incorpora una visualización de depuración que permite comprobar el funcionamiento de los módulos principales. Sobre la imagen procesada se representan el esqueleto detectado, los landmarks anatómicos calculados y la información de estado del sistema.

La interfaz visual debe mostrar únicamente la información necesaria para interpretar el comportamiento del sistema, evitando sobrecargar la imagen con datos técnicos excesivos. Entre los elementos más relevantes se encuentran:

- Orientación detectada de la persona.
- Landmark anatómico utilizado como referencia.
- Profundidad estimada o suavizada.
- Estado de distancia.
- Acción final generada.

Esta visualización resulta útil tanto durante el desarrollo como durante las demostraciones, ya que permite relacionar lo que el sistema detecta en la imagen con la acción que finalmente envía al robot. Además, facilita la identificación de errores, como pérdida de landmarks, orientación no válida o cambios bruscos en la profundidad.

Desde el punto de vista del diseño, la interfaz no se plantea como una aplicación final de usuario clínico, sino como una herramienta experimental de validación. Su objetivo principal es permitir observar la cadena completa de percepción, decisión y actuación de forma comprensible.

4. Implementación

En este capítulo se describe la implementación práctica del sistema diseñado en el capítulo anterior. La arquitectura final se organiza en varios procesos independientes, ya que los módulos de pose, profundidad y comunicación robótica requieren entornos de ejecución diferentes. En concreto, el sistema se apoya en cinco scripts principales: *depth_da3_server.py*, *realsense_pose_server.py*, *landmarks_unified.py*, *publish_mobile_pose_topics.py* y *ros2_to_android_bridge.py*.

Para facilitar la comprensión inicial de la implementación, la Tabla 4.1 resume los scripts principales desarrollados y su función dentro de la arquitectura. Esta tabla permite obtener una visión general del papel de cada componente antes de describirlos con mayor detalle en los apartados posteriores.

Tabla 4.1: Scripts principales de la arquitectura implementada

Script	Propósito general
<i>depth_da3_server.py</i>	Ejecuta Depth Anything 3 en un servidor HTTP local y permite consultar la profundidad estimada en uno o varios puntos anatómicos de la imagen.
<i>landmarks_unified.py</i>	Implementa el motor principal de landmarks. Ejecuta RTMPose, procesa los keypoints corporales, valida la orientación frontal y calcula los landmarks anatómicos externos.
<i>realsense_pose_server.py</i>	Captura imagen RGB desde la cámara RealSense, llama al motor de landmarks, consulta la profundidad en Depth Anything 3 y genera la acción final del sistema.
<i>publish_mobile_pose_topics.py</i>	Lee los resultados generados por el sistema principal y los publica en distintos topics de ROS2, incluyendo imagen, landmarks, orientación, profundidad y acción.
<i>ros2_to_android_bridge.py</i>	Se suscribe al topic de acción final en ROS2 y transmite dicha acción a la aplicación Android mediante una conexión TCP sobre WiFi.

El flujo de ejecución comienza con el servidor local de Depth Anything 3, implementado en *depth_da3_server.py*. Este servidor recibe imágenes y puntos anatómicos, ejecuta el modelo

de profundidad y devuelve los valores estimados en dichos puntos. A continuación, *realsense_pose_server.py* captura imagen RGB desde la cámara RealSense, ejecuta el motor de landmarks definido en *landmarks_unified.py*, consulta el servidor de profundidad y genera la acción final del sistema.

Los resultados se guardan en la carpeta *mobile_output*, concretamente en los ficheros *latest_frame.jpg* y *latest_landmarks.json*. Posteriormente, el script *publish_mobile_pose_topics.py* lee dichos ficheros y publica la información en ROS2. Finalmente, *ros2_to_android_bridge.py* se suscribe al topic de acción y envía dicha información a la aplicación Android mediante TCP/WiFi, para que esta la traduzca a comandos Bluetooth enviados al MiniCERNBot.

Esta división permite mantener separados los entornos de ejecución: Depth Anything 3 se ejecuta en su propio entorno, RTMPose y OpenMMLab en otro, y ROS2 Humble en el entorno del sistema. De esta forma se evitan conflictos de dependencias y se facilita la depuración de cada módulo por separado.

4.1 Hardware utilizado

El sistema implementado combina varios elementos hardware con funciones diferenciadas. La cámara se encarga de obtener la imagen RGB de la persona, el ordenador ejecuta los modelos de visión artificial y ROS2, el dispositivo Android actúa como intermediario de comunicación y el robot MiniCERNBot ejecuta finalmente las acciones de movimiento.

La Tabla 4.2 resume los principales elementos utilizados.

Tabla 4.2: Hardware utilizado en la implementación del sistema

Elemento	Función dentro del sistema
Cámara Intel RealSense	Captura de imagen RGB utilizada como entrada para RTMPose y Depth Anything 3.
Equipo de procesamiento	Ejecución de los modelos de visión artificial, estimación de profundidad, lógica de decisión y nodos ROS2.
Dispositivo Android	Recepción de acciones desde el PC y envío de comandos al robot mediante Bluetooth.
MiniCERNBot	Plataforma móvil utilizada para validar el posicionamiento autónomo.

4.1.1 Cámara Intel RealSense

La cámara Intel RealSense se utilizó como fuente principal de imagen RGB. Aunque este tipo de cámara dispone también de información de profundidad, en la arquitectura final se empleó principalmente su flujo de color, ya que la estimación de profundidad utilizada para la toma de decisiones se basó en Depth Anything 3.

El uso de la RealSense como cámara RGB permitió disponer de una fuente de imagen estable y fácilmente integrable en el sistema de percepción. A partir de los frames capturados se ejecutaba RTMPose para detectar la pose humana y Depth Anything 3 para obtener el mapa de profundidad monocular asociado.

4.1.2 Equipo de procesamiento

El equipo de procesamiento fue el encargado de ejecutar los módulos más pesados del sistema. En él se ejecutaron los entornos de OpenMMLab, Depth Anything 3 y ROS2 Humble. La disponibilidad de GPU resultó importante para acelerar la inferencia de los modelos de visión artificial, especialmente RTMPose y Depth Anything 3.

Además de ejecutar los modelos, el ordenador actuó como nodo central de la arquitectura. Desde él se generaban los landmarks anatómicos, se consultaba la profundidad asociada a dichos puntos, se aplicaba la lógica de decisión y se publicaba la información relevante en ROS2.

4.1.3 Dispositivo Android

El dispositivo Android se utilizó como intermediario entre el ordenador y el MiniCERNBot. Su función principal fue recibir las acciones generadas por el sistema en el PC mediante una conexión WiFi y enviarlas posteriormente al robot mediante Bluetooth.

Esta solución permitió desacoplar el procesamiento pesado de la actuación robótica. El ordenador ejecuta los modelos de visión artificial, la estimación de profundidad y ROS2, mientras que el teléfono actúa como puente de comunicación. De esta forma, el robot no necesita ejecutar directamente ROS2 ni los modelos de inteligencia artificial, sino únicamente recibir comandos simples de movimiento.

4.1.4 MiniCERNBot

El MiniCERNBot fue la plataforma móvil utilizada para validar el comportamiento del sistema. Su función dentro del proyecto consistió en ejecutar las acciones generadas por la lógica de decisión, como avanzar, retroceder, detenerse o corregir lateralmente la posición.

La integración con el robot permitió comprobar que la información obtenida mediante visión artificial podía transformarse en movimiento real. De esta manera, el sistema dejó de ser únicamente una arquitectura de percepción para convertirse en una cadena completa de percepción, decisión y actuación.

La Figura 4.1 muestra el montaje físico utilizado durante las pruebas, donde la cámara Intel RealSense se encuentra acoplada a la estructura del MiniCERNBot. Esta disposición permite que la imagen capturada represente la perspectiva frontal del robot, lo que resulta necesario para calcular los landmarks anatómicos, estimar la profundidad relativa y generar las acciones de posicionamiento.



Figura 4.1: Montaje físico del MiniCERNBot con la cámara Intel RealSense utilizada como fuente RGB.

4.2 Entornos de software

La implementación final requiere tres entornos de software diferenciados. Esta separación fue necesaria debido a las incompatibilidades entre las dependencias de OpenMMLab, Depth Anything 3 y ROS2 Humble.

4.2.1 Entorno OpenMMLab

El entorno OpenMMLab se utiliza para ejecutar RTMPose mediante MMPose. En este entorno se ejecuta principalmente *realsense_pose_server.py*, que importa el motor definido en *landmarks_unified.py*. Este motor recibe frames RGB, aplica RTMPose, selecciona la persona principal detectada, calcula la orientación y obtiene los landmarks anatómicos externos.

4.2.2 Entorno Depth Anything 3

Depth Anything 3 se ejecuta en un entorno separado mediante el script *depth_da3_server.py*. Este script levanta un servidor local en *127.0.0.1:8765* y expone los endpoints */health*, */depth_at_point* y */depth_at_points*. En la versión final se utiliza principalmente */depth_at_points*, ya que permite enviar una única imagen junto con varios puntos anatómicos y obtener la profundidad de todos ellos tras una sola ejecución del modelo.

4.2.3 Entorno ROS2 Humble

ROS2 Humble se ejecuta en el entorno del sistema, utilizando Python del sistema en lugar del entorno de OpenMMLab. En este entorno se ejecutan los scripts *publish_mobile_pose_topics.py* y *ros2_to_android_bridge.py*. El primero publica en ROS2 la información generada por el sistema de percepción, mientras que el segundo envía la acción final a la aplicación Android mediante TCP/WiFi.

4.3 Implementación del módulo de pose

El módulo de pose se implementó en el archivo *landmarks_unified.py*. Este script contiene la clase *LandmarksEngine*, encargada de ejecutar RTMPose, obtener los keypoints corporales, validar la orientación frontal de la persona y calcular los landmarks anatómicos externos utilizados por el sistema.

4.3.1 Integración de RTMPose

La integración de RTMPose se realiza mediante *MMPoseInferencer*, utilizando el modelo de pose humana disponible en MMPose. Cada frame RGB se procesa mediante el método *process_frame*, que devuelve la imagen anotada, los keypoints detectados, sus puntuaciones de confianza, los landmarks calculados y la orientación estimada.

4.3.2 Motor de landmarks

El motor de landmarks calcula cuatro referencias anatómicas externas: *neck_base*, *thyroid*, *pelvis* y *prostate*. La base cervical se calcula como el punto medio entre ambos hombros, la región tiroidea aproximada como una interpolación entre la base cervical y la nariz, el centro pélvico como el punto medio entre ambas caderas y la región prostática aproximada como un desplazamiento vertical desde la pelvis en función de la anchura de caderas.

4.3.3 Filtrado por confianza

El cálculo de landmarks se condiciona a la confianza de los keypoints detectados. En la implementación se utilizan umbrales diferenciados para puntos corporales y faciales. En la configuración

final del sistema se emplea un umbral de cuerpo de 0.3 y un umbral facial de 0.5. Además, la orientación frontal se suaviza temporalmente mediante contadores de frames consecutivos, evitando cambios bruscos entre *front* y *not_front*.

4.4 Implementación del módulo de profundidad

El módulo de profundidad se implementó mediante el script *depth_da3_server.py*. Este script carga el modelo Depth Anything 3 y lo expone como un servidor HTTP local. De esta forma, el resto del sistema puede consultar profundidad sin ejecutar directamente el modelo dentro del mismo proceso.

4.4.1 Servidor local de Depth Anything 3

El servidor se ejecuta en *127.0.0.1:8765*. El endpoint */health* permite comprobar que el servidor está activo. El endpoint */depth_at_point* permite consultar la profundidad en un único punto, mientras que */depth_at_points* permite consultar varios puntos en una sola petición.

En la versión final del sistema se utiliza */depth_at_points*, ya que permite enviar simultáneamente los landmarks *thyroid* y *prostate*. Esta decisión reduce el tiempo de procesamiento, porque Depth Anything 3 se ejecuta una sola vez sobre la imagen y después se extrae la profundidad en los puntos solicitados.

4.4.2 Consulta de profundidad en puntos anatómicos

La consulta de profundidad se realiza desde *realsense_pose_server.py*. Este script codifica el frame RGB como imagen JPEG en base64 y envía al servidor DA3 un diccionario de puntos anatómicos. En la configuración final se utilizan como objetivos principales *thyroid* y *prostate*, con prioridad para *thyroid*. Si la región tiroidea no está disponible, el sistema puede utilizar la región prostática.

La profundidad se calcula en una ventana local alrededor de cada punto, con un tamaño de ventana de 25 píxeles. Dentro de esta ventana se filtran valores no válidos y se obtiene una medida robusta mediante la mediana. El valor resultante se interpreta como una señal relativa de proximidad, no como una distancia métrica absoluta.

4.4.3 Optimización de llamadas al modelo

Para mejorar la eficiencia, *realsense_pose_server.py* no consulta Depth Anything 3 en todos los frames, sino cada cierto número de frames. En la configuración utilizada, la consulta se realiza cada tres frames. Además, se mantiene una caché con los últimos valores disponibles, de forma que el sistema puede seguir funcionando entre consultas consecutivas.

También se aplica suavizado temporal mediante buffers de profundidad y de estado. La profundidad se suaviza con una ventana de cinco valores y la clasificación final se estabiliza mediante mayoría temporal sobre los últimos estados. Esta estrategia reduce oscilaciones en la acción generada.

4.5 Implementación con RealSense

La integración con la cámara RealSense se realiza en el script *realsense_pose_server.py*. En la versión final del sistema, la RealSense se utiliza principalmente como cámara RGB. Aunque el dispositivo dispone de sensor de profundidad, la lógica final de posicionamiento no se basa directamente en la profundidad nativa de la cámara, ya que durante las pruebas se observó que la lectura local en torno a landmarks anatómicos pequeños podía presentar variaciones importantes entre frames, valores no válidos y saltos bruscos.

Esta variabilidad hacía que la señal no fuera suficientemente fiable para alimentar directamente una lógica de decisión basada en acciones discretas. En particular, una variación puntual en la profundidad podía provocar que el sistema cambiara de forma repentina entre estados como *CERCA*, *BIEN_DISTANCIA* o *LEJOS*. Por este motivo, la RealSense se empleó como fuente de imagen RGB estable para RTMPose y Depth Anything 3, mientras que su profundidad se utilizó principalmente como referencia experimental en la comparativa de resultados.

La Figura 4.2 muestra una ejecución real del sistema implementado. En la imagen se observa la salida generada por *realsense_pose_server.py*, donde aparecen la orientación detectada, el landmark utilizado como objetivo, la profundidad estimada mediante Depth Anything 3, el estado de distancia y la acción final generada.




Figura 4.2: Ejecución en tiempo real del sistema con RealSense, RTMPose, Depth Anything 3 y generación de acciones de movimiento.

4.5.1 Uso de RealSense como cámara RGB

La cámara se configura con una resolución de 640x480 píxeles y una frecuencia de 15 FPS. Cada frame RGB se envía al motor de landmarks, se utiliza para consultar Depth Anything 3 y posteriormente se anota con información visual de depuración, como orientación, target seleccionado, profundidad suavizada, estado de distancia y acción final.

4.5.2 Captura y procesamiento de frames

El procesamiento de cada frame sigue la siguiente secuencia:

1. Captura de imagen RGB desde la RealSense.
2. Ejecución de RTMPose mediante *LandmarksEngine*.
3. Cálculo de landmarks anatómicos externos.
4. Validación de orientación frontal.
5. Consulta de profundidad en *thyroid* y *prostate* mediante el servidor DA3.
6. Clasificación de distancia y centrado horizontal.
7. Generación de la acción final.
8. Guardado de resultados en *mobile_output/latest_frame.jpg* y *mobile_output/latest_landmarks.json*.

4.6 Publicación de datos en ROS2

La publicación de datos en ROS2 se implementó mediante el script *publish_mobile_pose_topics.py*. Este nodo lee periódicamente los ficheros generados por *realsense_pose_server.py*: *mobile_output/latest_frame.jpg* y *mobile_output/latest_landmarks.json*. Cuando detecta cambios en estos archivos, publica la información correspondiente en distintos topics ROS2.

4.6.1 Topics de imagen y landmarks

Los principales topics relacionados con imagen y landmarks son:

- */pose_app/image/compressed*
- */pose_app/thyroid*
- */pose_app/prostate*
- */pose_app/keypoints*
- */pose_app/all_landmarks*
- */pose_app/orientation*
- */pose_app/measurement_allowed*
- */pose_app/debug*

4.6.2 Topics de profundidad y acción

Además de los datos anatómicos, el publicador ROS2 expone la información de distancia y decisión generada por el sistema. Entre los topics más relevantes se encuentran los relacionados con la profundidad estimada, el estado de distancia, el objetivo seleccionado y la acción final enviada al robot.


Durante la ejecución del sistema, la salida del comando *ros2 topic list* mostró los siguientes topics:

- */pose_app/all_landmarks*
- */pose_app/debug*
- */pose_app/distance/action*
- */pose_app/distance/instant_state*
- */pose_app/distance/measurement_allowed*
- */pose_app/distance/near_threshold*
- */pose_app/distance/raw_depth*
- */pose_app/distance/smooth_depth*
- */pose_app/distance/state*
- */pose_app/distance/target*
- */pose_app/image/compressed*

- `/pose_app/keypoints`
- `/pose_app/measurement_allowed`
- `/pose_app/orientation`
- `/pose_app/prostate`
- `/pose_app/thyroid`

El topic más importante para el movimiento del robot es `/pose_app/distance/action`, ya que contiene la acción final generada por la lógica de decisión. Esta acción puede tomar valores como *ACERCAR*, *ALEJAR*, *PARAR* o acciones combinadas de distancia y centrado horizontal.

La Figura 4.3 muestra la salida del comando `ros2 topic list` durante la ejecución del sistema. En ella se observan los topics publicados por el nodo `publish_mobile_pose_topics.py`, junto con los topics propios de ROS2, como `/parameter_events` y `/rosout`.



```

marta@marta-HP-Spectre-x360-Convertible-15-eb0xxx:~/Documents/4º/practicas/RTMPo
se$ ros2 topic list
/parameter_events
/pose_app/all_landmarks
/pose_app/debug
/pose_app/distance/action
/pose_app/distance/instant_state
/pose_app/distance/measurement_allowed
/pose_app/distance/near_threshold
/pose_app/distance/raw_depth
/pose_app/distance/smooth_depth
/pose_app/distance/state
/pose_app/distance/target
/pose_app/image/compressed
/pose_app/keypoints
/pose_app/measurement_allowed
/pose_app/orientation
/pose_app/prostate
/pose_app/thyroid
/rosout

```

Figura 4.3: Salida del comando `ros2 topic list` durante la ejecución del sistema.

4.7 Implementación del puente ROS2–Android

La comunicación entre ROS2 y la aplicación Android se implementó mediante el script `ros2_to_android_bridge.py`. Este nodo se suscribe al topic `/pose_app/distance/action`, almacena la última acción recibida y abre un servidor TCP en el puerto 9999.

La aplicación Android se conecta a la dirección IP del ordenador y a dicho puerto mediante WiFi. Una vez establecida la conexión, el puente envía periódicamente un mensaje JSON con la acción más reciente y una marca temporal. Este formato permite que Android reciba acciones simbólicas como *ACERCAR*, *ALEJAR*, *PARAR*, *IZQUIERDA*, *DERECHA* o acciones combinadas.

Esta solución permite desacoplar ROS2 del control Bluetooth del MiniCERNBot. El ordenador se encarga de la percepción y la decisión, mientras que Android actúa como intermediario entre la red WiFi y la comunicación Bluetooth con el robot.

4.8 Implementación de la aplicación Android

La aplicación Android se utilizó como intermediaria entre el ordenador y el MiniCERNBot. Su función fue recibir acciones simbólicas desde el PC y transformarlas en comandos de movimiento enviados por Bluetooth.

4.8.1 Recepción de acciones por WiFi

La aplicación Android recibe las acciones generadas por el sistema mediante una conexión WiFi. Estas acciones pueden ser comandos simples, como *ACERCAR*, *ALEJAR* o *PARAR*, o acciones combinadas, como *ACERCAR_IZQUIERDA* o *ALEJAR_DERECHA*.

La recepción por WiFi permite mantener el procesamiento principal en el ordenador y utilizar el móvil únicamente como puente de comunicación. Esto resulta especialmente útil porque los modelos de visión artificial requieren más capacidad computacional de la que sería razonable ejecutar directamente en el dispositivo móvil.

4.8.2 Envío de comandos por Bluetooth

Una vez recibida la acción desde el PC, la aplicación Android la convierte en un comando de movimiento para el MiniCERNBot. Este comando se envía mediante Bluetooth al robot.

La correspondencia entre acciones y movimientos se basa en la lógica definida en el capítulo de diseño. Por ejemplo, la acción *ACERCAR* se traduce en avance, *ALEJAR* en retroceso y *PARAR* en detención. Las acciones laterales permiten corregir el centrado horizontal del robot respecto a la persona.

4.8.3 Inicialización automática de velocidad

Durante las pruebas se observó que, tras ciertas acciones de parada o reinicio, era necesario asegurar que la velocidad del robot estuviera correctamente inicializada antes de enviar nuevos comandos. Por ello, se incorporó una inicialización automática de velocidad en la aplicación.

Esta inicialización permitió evitar situaciones en las que el robot recibía una acción válida, pero no se movía debido a que la velocidad no había sido configurada correctamente. De esta forma, la aplicación garantizaba que el robot estuviera preparado para ejecutar las órdenes recibidas.

4.9 Implementación de la lógica de movimiento

La lógica de movimiento fue implementada a partir de los estados de distancia y centrado horizontal calculados por el sistema. Su finalidad fue convertir la percepción visual en acciones simples y combinadas que el robot pudiera ejecutar.

4.9.1 Acciones simples

Las acciones simples corresponden a movimientos básicos del robot. Las principales acciones implementadas fueron:

- *ACERCAR*: el robot avanza hacia la persona.
- *ALEJAR*: el robot retrocede respecto a la persona.
- *PARAR*: el robot se detiene.
- *IZQUIERDA*: el robot corrige lateralmente su posición hacia la izquierda.
- *DERECHA*: el robot corrige lateralmente su posición hacia la derecha.

Estas acciones se generaban en función de la distancia relativa y del error horizontal del landmark seleccionado respecto al centro de la imagen.

4.9.2 Acciones combinadas

Además de las acciones simples, se implementaron acciones combinadas para permitir que el robot regulara distancia y centrado al mismo tiempo. Por ejemplo, si la persona estaba lejos y además aparecía desplazada lateralmente en la imagen, el sistema podía generar una acción como *ACERCAR_IZQUIERDA* o *ACERCAR_DERECHA*.

Este tipo de acción permitió un comportamiento más flexible que una lógica secuencial. El robot no necesitaba primero acercarse y después corregir lateralmente, sino que podía combinar ambos movimientos dentro de una misma decisión.

4.9.3 Parada de seguridad

La parada de seguridad se implementó como acción por defecto ante cualquier situación de incertidumbre. Si no se detectaba una persona, si la orientación no era válida, si los landmarks no podían calcularse o si no existía una profundidad fiable, el sistema generaba la acción *PARAR*.

Este comportamiento es fundamental en un sistema robótico asistencial, ya que evita movimientos no deseados cuando la percepción no es suficientemente fiable. Además, la parada también se utiliza cuando el robot alcanza una distancia adecuada y se encuentra centrado frente a la persona.

4.10 Problemas encontrados y soluciones aplicadas

Durante la implementación aparecieron varios problemas técnicos derivados de la integración de herramientas heterogéneas. Estos problemas no afectaron al objetivo final del proyecto, pero sí condicionaron la arquitectura implementada.

Uno de los problemas principales fue la incompatibilidad entre entornos de ejecución. RTMPose, Depth Anything 3 y ROS2 requerían dependencias distintas, por lo que no fue viable ejecutarlos todos dentro de un único entorno Python. La solución adoptada fue separar los módulos en procesos independientes y comunicar sus salidas mediante servicios locales, ficheros compartidos y topics ROS2.

Otro problema fue la estabilidad de la profundidad estimada. Los valores obtenidos mediante Depth Anything 3 podían oscilar entre frames consecutivos, incluso cuando la escena apenas cambiaba. Para reducir este efecto, se incorporó una lectura robusta mediante ventana local y un suavizado temporal de la señal.

También se observó que la lógica de movimiento podía generar oscilaciones si reaccionaba a pequeñas variaciones de profundidad. Para solucionarlo, se incorporó un bloqueo de posición alcanzada, de forma que el robot mantuviera la parada cuando se encontraba en una situación válida y solo volviera a moverse ante cambios suficientemente significativos.

Además, la comunicación con el robot requirió separar claramente las responsabilidades entre PC, Android y MiniCERNBot. El PC se mantuvo como unidad de procesamiento, Android como puente de comunicación y el robot como plataforma de actuación. Esta división permitió validar el sistema completo sin necesidad de ejecutar ROS2 directamente sobre el robot.

En conjunto, las soluciones aplicadas permitieron obtener una arquitectura funcional capaz de capturar imagen, detectar pose humana, calcular landmarks anatómicos externos, estimar profundidad relativa, publicar información en ROS2, enviar acciones a Android y ejecutar movimientos sobre el MiniCERNBot.

5. Experimentación y validación

En este capítulo se describen las pruebas realizadas para validar los distintos módulos del sistema desarrollado. La experimentación se organizó de forma progresiva, comenzando por la detección de pose y landmarks anatómicos, continuando con la estimación de profundidad y finalizando con la validación de la lógica de decisión y la integración con el robot MiniCERNBot.

El objetivo principal de estas pruebas no fue obtener una validación clínica del sistema, ya que el proyecto no aborda la medición radiológica real, sino comprobar que la arquitectura implementada era capaz de transformar información visual en acciones de posicionamiento útiles para un robot móvil.

5.1 Metodología experimental

La metodología experimental se estructuró en varias fases, con el objetivo de validar de forma progresiva los módulos principales del sistema: detección de pose, cálculo de landmarks anatómicos, validación de orientación, estimación de profundidad, lógica de decisión e integración robótica.

Las pruebas se realizaron en un entorno experimental controlado de laboratorio, situando a una persona frente al sistema y modificando su distancia, orientación y posición horizontal respecto a la cámara. Estas condiciones permitieron evaluar de forma separada la detección de pose, la estabilidad de los landmarks, la señal de profundidad y la respuesta de la lógica de movimiento. El sistema se probó principalmente con la cámara Intel RealSense como fuente RGB, ejecutando RTMPose, Depth Anything 3 y los nodos ROS2 necesarios para publicar la información generada.

El entorno de validación correspondió a un espacio interior de laboratorio, con iluminación artificial estable y sin cambios bruscos de luz durante las pruebas. La persona se situó frente al robot en distintas posiciones relativas, simulando situaciones de cercanía, distancia adecuada y lejanía respecto al sistema. Asimismo, se realizaron pruebas con desplazamientos laterales respecto al centro de la imagen para comprobar la respuesta de la lógica de centrado horizontal. Las pruebas se llevaron a cabo con ropa habitual y no con indumentaria hospitalaria específica, por lo que esta condición debe considerarse una limitación del entorno experimental.

La Figura 5.1 muestra el entorno utilizado durante la validación del sistema. En ella se puede observar la disposición general del robot MiniCERNBot, la persona situada frente al sistema y

el espacio de laboratorio en el que se realizaron las pruebas. Esta imagen permite contextualizar físicamente las condiciones de validación y la relación espacial entre el robot, la cámara y la persona.



Figura 5.1: Entorno experimental utilizado para la validación del sistema, con el robot MiniCERN-Bot situado frente a la persona en el laboratorio de pruebas.

Las pruebas no se plantearon como un protocolo clínico exhaustivo, sino como una validación experimental progresiva de los módulos desarrollados. Por este motivo, las condiciones de distancia se interpretaron como estados funcionales para la toma de decisiones del robot, y no como posiciones clínicas estrictamente protocolizadas. El objetivo principal fue comprobar si el sistema era capaz de distinguir situaciones útiles para el posicionamiento: persona demasiado cerca, persona en una distancia considerada adecuada, persona demasiado lejos y persona descentrada horizontalmente respecto al robot.

Durante el desarrollo se realizaron numerosas pruebas generales de funcionamiento. Estas pruebas tuvieron un carácter iterativo y sirvieron para comprobar, ajustar y depurar los distintos módulos del sistema: captura de imagen, detección de pose, cálculo de landmarks anatómicos, validación de orientación, lectura de profundidad, publicación de topics en ROS2, comunicación con Android y generación de acciones de movimiento. Estas pruebas generales permitieron avanzar progresivamente desde módulos aislados hasta una arquitectura integrada.

Además de estas pruebas generales, se diseñó una comparativa específica entre la profundidad proporcionada por la cámara RealSense y la profundidad estimada mediante Depth Anything 3. En esta comparativa se utilizó una persona situada frente a la cámara, con ropa habitual y en un entorno de laboratorio con fondo fijo. Aunque durante el desarrollo se realizaron pruebas en distintos puntos del laboratorio, la comparativa cuantitativa se planteó manteniendo constantes las condiciones de captura, con el objetivo de comparar ambos métodos sobre las mismas imágenes.

Las distancias reales de referencia utilizadas en esta comparativa fueron 0.5 m, 0.7 m, 1.0 m, 1.2 m, 1.5 m y 2.0 m. Para cada una de estas distancias se registró una secuencia breve con la persona situada de forma aproximadamente fija frente a la cámara. A partir de estas secuencias se

obtuvieron los valores de profundidad asociados al landmark seleccionado. Además, se conservó un fotograma representativo de cada distancia para documentar visualmente la prueba. De este modo, ambos métodos se evaluaron utilizando las mismas secuencias, los mismos landmarks y las mismas distancias reales de referencia.

La Tabla 5.1 resume las condiciones utilizadas en la comparativa específica de profundidad.

Tabla 5.1: Condiciones de la comparativa entre RealSense y Depth Anything 3

Aspecto evaluado	Condición experimental
Persona evaluada	Una persona situada frente al sistema.
Ropa	Ropa habitual, sin indumentaria hospitalaria específica.
Entorno	Laboratorio interior con fondo fijo durante la comparativa.
Iluminación	Iluminación artificial interior estable.
Distancias de referencia	0.5 m, 0.7 m, 1.0 m, 1.2 m, 1.5 m y 2.0 m.
Captura por distancia	Secuencia breve en posición fija y fotograma representativo para cada distancia de referencia.
Métodos comparados	Profundidad proporcionada por RealSense y profundidad estimada mediante Depth Anything 3.
Condición de comparación	Ambos métodos se evaluaron sobre las mismas secuencias, los mismos landmarks y las mismas distancias reales de referencia.

En primer lugar, se comprobaron los resultados de detección de pose humana mediante RTM-Pose y el cálculo de landmarks anatómicos externos. Estas pruebas permitieron verificar que el sistema era capaz de identificar keypoints corporales relevantes y derivar referencias como la base cervical, la región tiroidea aproximada, el centro pélvico y la región prostática aproximada.

En segundo lugar, se realizaron pruebas específicas de orientación del paciente. Dado que la aplicación prevista requiere que el paciente esté colocado de frente al sistema, se evaluó si la lógica de frontalidad permitía diferenciar situaciones válidas de situaciones no adecuadas para la medición. Para ello se analizaron casos en los que la persona aparecía frontalmente y situaciones en las que la orientación podía resultar menos fiable.

En tercer lugar, se analizaron pruebas de profundidad con Depth Anything 3. Inicialmente se realizaron pruebas offline sobre imágenes y secuencias previamente guardadas, con el objetivo de comprobar si los valores estimados variaban de forma coherente cuando la persona se encontraba cerca o lejos de la cámara. Posteriormente, se integró la estimación de profundidad en tiempo real, asociando la lectura de profundidad a los landmarks anatómicos seleccionados.

En cuarto lugar, se comparó la profundidad estimada mediante Depth Anything 3 con la profundidad proporcionada por la cámara RealSense. Para ello se utilizaron las secuencias registradas a las distancias reales de referencia indicadas anteriormente. Esta comparación permitió valorar tanto la precisión métrica como la estabilidad temporal de ambas fuentes de profundidad, calculando métricas como tasa de valores válidos, desviación típica temporal, diferencia entre frames consecutivos, MAE, RMSE y MAPE.

Además de las pruebas visuales, se registraron resultados en ficheros CSV para analizar cuantitativamente el comportamiento de la profundidad estimada. Estos registros permitieron comparar métodos, landmarks y condiciones de distancia, así como calcular métricas de estabilidad y error respecto a una distancia real de referencia.

Finalmente, se validó la lógica de decisión y la integración con el robot MiniCERNBot. En esta fase se comprobó que los estados generados por el sistema podían transformarse en acciones de movimiento como *ACERCAR*, *ALEJAR*, *PARAR* y correcciones laterales. La validación final permitió comprobar la cadena completa de percepción, decisión, comunicación y actuación robótica.

En conjunto, la metodología experimental permitió validar el sistema en condiciones controladas

y comprobar su funcionamiento como prueba de concepto. No obstante, al haberse realizado en un entorno de laboratorio y con una única persona en la comparativa específica de profundidad, los resultados deben interpretarse dentro de ese contexto. Una validación futura debería ampliar el número de personas evaluadas, incorporar ropa hospitalaria, aumentar el número de capturas por distancia, registrar secuencias más largas y analizar el comportamiento del sistema ante cambios de iluminación, oclusiones y variaciones del entorno.

5.2 Pruebas de detección de pose

Las primeras pruebas se centraron en comprobar el funcionamiento de RTMPose sobre imágenes y vídeo. El objetivo era verificar que el modelo detectaba correctamente la estructura corporal de la persona y proporcionaba keypoints suficientemente estables para calcular landmarks anatómicos externos.

Durante estas pruebas se prestó especial atención a los keypoints necesarios para el proyecto: hombros, caderas, nariz y ojos. Los hombros resultan necesarios para calcular la base cervical, la nariz permite aproximar la región tiroidea, las caderas permiten obtener el centro pélvico y los ojos, junto con la nariz, se emplean para validar la orientación frontal.

La Figura 5.2 muestra un ejemplo de las primeras pruebas de detección de pose realizadas con RTMPose. En la imagen se observa la estimación del esqueleto corporal sobre la persona detectada, lo que permitió comprobar que el modelo proporcionaba los keypoints necesarios para las fases posteriores del sistema.



Figura 5.2: Ejemplo de prueba inicial de detección de pose humana mediante RTMPose.

Los resultados obtenidos permitieron confirmar que RTMPose era adecuado para la primera etapa de percepción del sistema. No obstante, también se observó que la salida del modelo podía verse afectada por oclusiones, posturas no frontales o detecciones con baja confianza. Por este motivo, se incorporó un filtrado por confianza y una validación adicional de la orientación antes de permitir la medición.

5.3 Pruebas de landmarks anatómicos

Una vez validada la detección de pose, se realizaron pruebas para comprobar el cálculo de landmarks anatómicos externos. Estos puntos no son detectados directamente por RTMPose, sino que se obtienen mediante relaciones geométricas entre keypoints corporales.

Las pruebas permitieron comprobar que la base cervical y el centro pélvico podían obtenerse de forma estable cuando ambos hombros y ambas caderas eran visibles. A partir de estos puntos se calcularon la región tiroidea aproximada y la región prostática aproximada.

La región tiroidea aproximada se mostró especialmente útil como referencia visual, ya que se sitúa en una zona visible del tronco superior y está relacionada con una región anatómica de interés para la aplicación planteada. La región prostática aproximada, por su parte, permitió obtener una referencia inferior del cuerpo, aunque su estabilidad dependió en mayor medida de la correcta detección de las caderas y de la postura de la persona.

Estas pruebas confirmaron la necesidad de tratar los landmarks como referencias externas aproximadas y no como posiciones clínicas exactas. Su utilidad principal dentro del sistema es guiar el posicionamiento del robot y delimitar zonas externas de interés para una posible medición posterior.

5.4 Pruebas de orientación del paciente

La orientación del paciente se evaluó como una condición previa para permitir la medición. En el escenario previsto, el paciente estaría colocado de frente al robot antes de realizar una medición localizada. Por tanto, el sistema no debe actuar únicamente porque detecte una persona, sino porque detecte una persona en una orientación compatible con la tarea.

Inicialmente se comprobó la presencia de puntos faciales como nariz y ojos. Sin embargo, durante las pruebas se observó que esta condición podía ser insuficiente, ya que el modelo podía detectar algunos keypoints faciales incluso cuando la persona no estaba completamente de frente. Por este motivo, se incorporó una validación geométrica adicional.

La lógica final de orientación considera la presencia de nariz y ojos, la alineación relativa entre ambos ojos, la posición de la nariz respecto a los ojos y la coherencia de la cara respecto al eje formado por los hombros. Además, se aplica un suavizado temporal mediante frames consecutivos para evitar cambios bruscos entre los estados *front* y *not_front*.

Estas pruebas permitieron reducir falsos positivos de frontalidad y asegurar que las acciones de posicionamiento se generaran únicamente en condiciones más coherentes con la aplicación hospitalaria prevista.

5.5 Pruebas iniciales de profundidad con Depth Anything 3

Las primeras pruebas de profundidad se realizaron con Depth Anything 3 sobre imágenes y secuencias previamente procesadas. El objetivo fue comprobar si el modelo proporcionaba una señal de profundidad que variaba de forma coherente al modificar la distancia entre la persona y la cámara.

En esta fase, la profundidad no se interpretó como una distancia métrica exacta, sino como una señal relativa. Para ello, se consultó el mapa de profundidad generado por Depth Anything 3 en torno a landmarks anatómicos concretos, utilizando una ventana local alrededor del punto para reducir el impacto de valores aislados.

La Figura 5.3 muestra una prueba inicial de lectura de profundidad en un landmark. En ella se observa cómo el sistema obtiene las coordenadas del punto seleccionado y consulta el valor de profundidad asociado.

```

(openmmlab) marta@marta-HP-Spectre-x360-Convertible-15-eb0xxx:~/Documents/4º/prac
ticas/RTMPose$ python leer_profundidad.py --json resultados/json/cerca.json
--npz ../depth_anything3/Depth-Anything-3/output_da3_cerca/results_output/frame_0
.npz --landmark pelvis --window 5
Landmark: pelvis
Coordenadas: x=127.38, y=270.32
Depth (5x5): 1.6442646980285645
(openmmlab) marta@marta-HP-Spectre-x360-Convertible-15-eb0xxx:~/Documents/4º/prac
ticas/RTMPose$ python leer_profundidad.py \
--json resultados/json/lejos.json \
--npz ../depth_anything3/Depth-Anything-3/output_da3_lejos/results_output/frame
_0.npz \
--landmark pelvis \
--window 5
Landmark: pelvis
Coordenadas: x=145.06, y=255.38
Depth (5x5): 2.766390562857495
(openmmlab) marta@marta-HP-Spectre-x360-Convertible-15-eb0xxx:~/Documents/4º/prac

```

Figura 5.3: Prueba offline de lectura de profundidad en un landmark anatómico mediante Depth Anything 3.

5.5.1 Lectura de profundidad en pelvis

Una de las primeras referencias analizadas fue el centro pélvico. Este landmark se calculó como el punto medio entre ambas caderas y se utilizó para consultar la profundidad en la zona media-inferior del cuerpo.

Las pruebas mostraron que la pelvis podía proporcionar una señal de profundidad útil, especialmente cuando las caderas eran detectadas con suficiente confianza. Sin embargo, también se observó que este punto podía verse afectado por la postura de la persona, la ropa y la posible oclusión parcial de la zona inferior del tronco.

Además, al estar situada en una zona más baja de la imagen, la pelvis podía verse afectada por variaciones en la perspectiva y por cambios en la posición de las piernas. Por ello, aunque resultó útil para las primeras pruebas, no fue necesariamente el landmark más estable para la toma de decisiones final.

5.5.2 Lectura de profundidad en base cervical

La base cervical, calculada como el punto medio entre ambos hombros, se analizó como alternativa para la estimación de profundidad. Este punto presentó varias ventajas prácticas. En primer lugar, depende de los hombros, que suelen ser visibles cuando la persona se encuentra de frente. En segundo lugar, se sitúa en una zona superior del tronco, más próxima a la región tiroidea aproximada. En tercer lugar, mostró una separación más clara entre situaciones de cercanía y lejanía en las pruebas iniciales.

En comparación con la pelvis, la base cervical ofreció una señal más coherente para estimar la proximidad relativa entre la persona y la cámara. Por este motivo, se consideró una referencia especialmente prometedora para la lógica de distancia.

5.5.3 Comparación entre landmarks

La comparación entre landmarks permitió observar que no todos los puntos anatómicos ofrecen la misma estabilidad ni la misma capacidad de separación entre distancia cercana y lejana. En las pruebas iniciales, la base cervical mostró una diferencia más clara entre situaciones de cerca y lejos que el centro pélvico.

La Tabla 5.2 resume una comparación representativa entre ambos landmarks durante las pruebas preliminares.

Tabla 5.2: Comparación preliminar de profundidad relativa entre landmarks

Landmark	Media cerca	Media lejos	Diferencia
Base cervical	1.43	2.01	0.58
Centro pélvico	1.85	2.18	0.33

Los valores mostrados en la Tabla 5.2 deben interpretarse como valores relativos de profundidad estimados por Depth Anything 3, no como distancias métricas exactas en metros. La columna *Media cerca* recoge el valor medio obtenido cuando la persona se encontraba próxima a la cámara, mientras que la columna *Media lejos* recoge el valor medio cuando la persona se encontraba a una mayor distancia.

La columna *Diferencia* indica la separación entre ambas situaciones. Un valor mayor en esta columna significa que el landmark permite distinguir mejor entre una persona cercana y una persona lejana. Por ejemplo, la base cervical presenta una diferencia de 0.58, mientras que el centro pélvico presenta una diferencia de 0.33. Esto indica que, en las pruebas preliminares, la base cervical ofreció una señal más discriminativa para clasificar la distancia relativa.

Por tanto, la tabla no pretende evaluar la precisión métrica absoluta de cada landmark, sino su utilidad como referencia relativa para la lógica de decisión del robot. Desde este punto de vista, un landmark resulta más útil cuanto mayor sea la separación entre los valores obtenidos en condiciones de cercanía y lejanía, siempre que la señal sea suficientemente estable entre fotogramas.

Estos resultados apoyaron la decisión de utilizar preferentemente landmarks superiores, como la base cervical o la región tiroidea aproximada, para estimar la proximidad relativa. No obstante, la región prostática aproximada se mantuvo dentro del sistema porque forma parte de las regiones anatómicas de interés definidas en el proyecto.

5.6 Comparativa entre RealSense y Depth Anything 3

Una vez realizadas las pruebas iniciales con Depth Anything 3, se llevó a cabo una comparativa con la profundidad proporcionada por la cámara RealSense. Esta comparación permitió analizar hasta qué punto la profundidad monocular podía utilizarse como señal relativa de proximidad y qué diferencias presentaba respecto a una cámara RGB-D.

Para ello, se capturaron secuencias en las que se registraban simultáneamente la profundidad de RealSense y la profundidad estimada por Depth Anything 3 en torno a landmarks anatómicos. Las pruebas se realizaron sobre los objetivos *thyroid* y *prostate*, utilizando una ventana local alrededor de cada punto.

La comparación se realizó mediante varias métricas:

- Tasa de valores válidos.
- Desviación típica temporal.
- Diferencia media entre frames consecutivos.
- Error absoluto medio.
- Raíz del error cuadrático medio.
- Error porcentual absoluto medio.

5.6.1 Tasa de valores válidos

La tasa de valores válidos mide la proporción de frames en los que el sistema pudo obtener una medida de profundidad válida. Se calcula como:

$$valid_rate = \frac{N_{valid}}{N_{total}} \quad (5.1)$$

donde N_{valid} representa el número de medidas válidas y N_{total} el número total de medidas consideradas.

Esta métrica permite evaluar la disponibilidad de la señal. En las pruebas realizadas, la tasa de valores válidos estuvo condicionada principalmente por la disponibilidad del landmark, la orientación frontal y la validez de la medida en la ventana local.

5.6.2 Desviación típica temporal

La desviación típica temporal se utilizó para analizar la estabilidad de la profundidad a lo largo de la secuencia. Un valor menor indica que la señal presenta menos variación entre frames, siempre que la escena permanezca aproximadamente constante.

$$\sigma_z = \sqrt{\frac{1}{N} \sum_{i=1}^N (z_i - \bar{z})^2} \quad (5.2)$$

donde z_i representa cada valor de profundidad y $\bar{z}$ la media de la secuencia.

Esta métrica resultó útil para observar el ruido temporal de cada método. No obstante, una señal con baja desviación típica no implica necesariamente que sea métricamente correcta, ya que también debe compararse con una distancia real de referencia.

5.6.3 Diferencia entre frames consecutivos

La diferencia media entre frames consecutivos mide la variación media de la señal entre dos instantes consecutivos:

$$\Delta z = \frac{1}{N-1} \sum_{i=2}^N |z_i - z_{i-1}| \quad (5.3)$$

Esta métrica permite valorar si la señal cambia bruscamente entre frames. En un sistema de control o decisión robótica, una señal con variaciones bruscas puede provocar oscilaciones en la acción generada. Por ello, esta métrica fue importante para justificar el uso de suavizado temporal.

5.6.4 MAE

El error absoluto medio, o MAE, se utilizó para comparar los valores de profundidad con una distancia real medida manualmente durante la prueba. Se calcula como:

$$MAE = \frac{1}{N} \sum_{i=1}^N |z_i - d_{real}| \quad (5.4)$$

donde d_{real} representa la distancia real de referencia. Esta métrica permite evaluar el error medio de cada método respecto a una medida externa.

5.6.5 RMSE

La raíz del error cuadrático medio, o RMSE, penaliza más los errores grandes que el MAE y se calcula como:

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (z_i - d_{real})^2} \quad (5.5)$$

Esta métrica resulta útil para identificar métodos que, aunque puedan tener errores medios moderados, presentan desviaciones puntuales relevantes.

5.6.6 MAPE

Además del MAE y el RMSE, se incorporó el error porcentual absoluto medio, o MAPE, con el objetivo de facilitar la interpretación relativa del error. A diferencia del MAE, que expresa el error en metros, el MAPE indica el error medio como porcentaje respecto a la distancia real de referencia.

El MAPE se calcula como:

$$MAPE = \frac{100}{N} \sum_{i=1}^N \left| \frac{z_i - d_{real}}{d_{real}} \right| \quad (5.6)$$

donde z_i representa la profundidad estimada, d_{real} la distancia real de referencia y N el número de muestras válidas consideradas.

Esta métrica resulta especialmente útil para comparar errores obtenidos a distintas distancias. Por ejemplo, un error absoluto de 0.1 m no tiene la misma importancia relativa si la persona se encuentra a 0.5 m que si se encuentra a 2.0 m. Por ello, el MAPE permite expresar la desviación de cada método en términos porcentuales y facilita la lectura global de los resultados.

La Tabla 5.3 muestra un resumen global representativo de la comparativa entre RealSense y Depth Anything 3.

Tabla 5.3: Resumen global de la comparativa entre RealSense y Depth Anything 3

Método	Tasa válida	Desv. típica	Dif. frames	MAE	RMSE	MAPE
RealSense	0.709	0.110	0.0189	0.144	0.181	12.94 %
Depth Anything 3	0.709	0.078	0.0120	0.419	0.426	29.21 %

Los resultados muestran que RealSense proporcionó una profundidad más adecuada desde el punto de vista métrico, al obtener menores valores de MAE, RMSE y MAPE. En concreto, RealSense presentó un MAPE global del 12.94 %, mientras que Depth Anything 3 obtuvo un MAPE del 29.21 %. Esto significa que, en términos relativos, la profundidad de RealSense se aproximó más a la distancia real de referencia.

Depth Anything 3, en cambio, mostró una señal temporalmente más estable, con una desviación típica y una diferencia media entre frames inferiores. Sin embargo, su error porcentual fue mayor, lo que refuerza su interpretación como señal relativa de proximidad y no como medida absoluta de distancia.

Debe señalarse que la mayor precisión métrica de RealSense no implicó su selección como señal final de control. Durante las pruebas, la lectura local de profundidad en torno a landmarks anatómicos pequeños podía presentar variaciones entre frames, valores no válidos o saltos bruscos. Estas fluctuaciones podían afectar a la clasificación de distancia y provocar cambios no deseados en la acción del robot. Por este motivo, RealSense se mantuvo como referencia experimental para la comparativa, mientras que Depth Anything 3 se utilizó en la arquitectura final como señal relativa de proximidad combinada con suavizado temporal.

5.7 Validación de la profundidad como señal relativa

La comparativa anterior permitió extraer una conclusión importante: Depth Anything 3 no debe utilizarse directamente como sensor métrico absoluto sin calibración adicional. Aunque el modelo genera valores numéricos de profundidad, estos no siempre coinciden con la distancia real medida.

Sin embargo, los experimentos mostraron que la señal generada por Depth Anything 3 sí puede ser útil para clasificar situaciones relativas. Es decir, aunque el sistema no pueda afirmar que la

persona se encuentra exactamente a una distancia determinada en metros, sí puede interpretar si la persona está más cerca, más lejos o dentro de un rango adecuado.

Esta interpretación resulta suficiente para el objetivo del proyecto, ya que la lógica de movimiento del robot no necesita una reconstrucción métrica precisa de la escena. El robot necesita saber si debe acercarse, alejarse, detenerse o corregir su posición. Por tanto, el uso de umbrales experimentales y suavizado temporal permite transformar la profundidad monocular en una señal funcional para la toma de decisiones.

5.8 Pruebas de decisión de movimiento

Una vez validada la señal de profundidad relativa, se probaron las acciones generadas por la lógica de decisión. Estas pruebas tuvieron como objetivo comprobar que el sistema respondía de forma coherente ante distintas posiciones de la persona respecto a la cámara.

5.8.1 Clasificación cerca, en rango y lejos

La clasificación de distancia se basó en la comparación de la profundidad suavizada con umbrales definidos experimentalmente. El sistema distinguió tres situaciones principales: persona demasiado cerca, persona en distancia adecuada y persona demasiado lejos.

La Figura 5.4 muestra ejemplos visuales de los tres estados funcionales y la acción generada en cada caso.



Figura 5.4: Ejemplos de clasificación de distancia y acción generada por el sistema en tres situaciones diferentes.

En el primer caso, la persona se encuentra demasiado cerca, por lo que el sistema genera la acción *ALEJAR*. En el segundo caso, la persona se encuentra dentro del rango adecuado y la acción generada es *PARAR*. En el tercer caso, la persona se encuentra demasiado lejos y el sistema genera la acción *ACERCAR*.

5.8.2 Centrado horizontal

Además de la distancia, se evaluó el centrado horizontal del landmark seleccionado. Esta prueba permitió comprobar si el robot podía determinar cuándo la persona aparecía desplazada hacia un lado de la imagen y generar una acción de corrección.

El sistema calcula el error horizontal entre la coordenada del landmark y el centro de la imagen. Si el error supera una tolerancia definida, se genera una acción lateral o combinada. Esta lógica es importante porque el objetivo no es únicamente situarse a una distancia adecuada, sino colocarse frente a la región anatómica de interés.

Durante las pruebas, el centrado horizontal permitió corregir situaciones en las que la distancia era adecuada, pero el landmark aparecía desplazado respecto al centro de la imagen. En estos casos, el sistema no debía detenerse completamente, sino generar una acción de corrección lateral.

5.8.3 Bloqueo de posición alcanzada

Las pruebas de decisión también mostraron la necesidad de incorporar un bloqueo de posición alcanzada. Sin este mecanismo, pequeñas variaciones en la señal de profundidad podían provocar cambios repetidos entre acciones como *ACERCAR*, *ALEJAR* y *PARAR*.

El bloqueo de posición permite mantener la acción *PARAR* cuando el sistema considera que el robot está en una posición válida. El robot solo vuelve a moverse si se detecta una variación suficientemente significativa y persistente. Esta estrategia mejora la estabilidad del comportamiento y evita oscilaciones provocadas por ruido en la profundidad o pequeñas variaciones en la detección de landmarks.

5.9 Pruebas de integración con MiniCERNBot

La integración con el MiniCERNBot permitió validar la cadena completa de percepción, decisión y actuación. En estas pruebas, el ordenador ejecutó los módulos de visión artificial y ROS2, la aplicación Android recibió las acciones mediante WiFi y el robot ejecutó los comandos mediante Bluetooth.

El flujo validado fue el siguiente:

RealSense RGB → RTMPose → landmarks anatómicos → Depth Anything 3 → decisión →
ROS2 → Android → Bluetooth → MiniCERNBot

Durante las pruebas se comprobó que el robot podía ejecutar acciones de avance, retroceso, parada y corrección lateral a partir de la información visual. También se comprobó que, ante situaciones no válidas, como pérdida de landmarks, orientación no frontal o ausencia de profundidad, la acción segura era detener el robot.

Estas pruebas confirmaron que la arquitectura no solo funcionaba como sistema de percepción, sino como una primera integración robótica completa capaz de transformar landmarks anatómicos y profundidad relativa en movimiento real.

6. Resultados y discusión

En este capítulo se presentan y discuten los resultados obtenidos tras la implementación y validación del sistema. A diferencia del capítulo anterior, centrado en describir las pruebas realizadas, este apartado analiza el comportamiento global de la arquitectura y valora hasta qué punto se han alcanzado los objetivos planteados.

Los resultados se organizan en torno a los principales módulos del sistema: percepción, landmarks anatómicos, profundidad, comparación entre RealSense y Depth Anything 3, lógica de decisión y movimiento autónomo del robot. Finalmente, se revisa el grado de consecución de los objetivos, las limitaciones observadas y la discusión general del trabajo.

6.1 Resultados del sistema de percepción

El sistema de percepción basado en RTMPose permitió detectar la pose humana en imágenes RGB y obtener los keypoints corporales necesarios para las etapas posteriores. En general, el modelo fue capaz de identificar de forma adecuada puntos como hombros, caderas, nariz y ojos cuando la persona se encontraba en una posición frontal y dentro del campo de visión de la cámara.

Estos resultados confirman que RTMPose es una opción adecuada para este proyecto, ya que proporciona una representación corporal suficientemente estructurada para calcular landmarks anatómicos externos. Además, su integración mediante el entorno OpenMMLab permitió utilizarlo dentro de una arquitectura propia y combinarlo con otros módulos, como la estimación de profundidad y la publicación en ROS2.

No obstante, también se observaron limitaciones propias de los modelos de estimación de pose. La detección puede verse afectada por la orientación de la persona, la oclusión parcial del cuerpo, la ropa holgada o la pérdida de confianza en algunos keypoints. Por este motivo, no se utilizó la salida del modelo de forma directa, sino que se incorporaron umbrales de confianza y una lógica de validación de orientación antes de permitir la medición.

En conjunto, el sistema de percepción cumplió su función principal: proporcionar una base visual estable para la detección de referencias anatómicas externas y para la posterior toma de decisiones del robot.

6.2 Resultados de la estimación de landmarks anatómicos

A partir de los keypoints detectados por RTMPose, el sistema fue capaz de calcular los landmarks anatómicos externos definidos en el proyecto: base cervical, región tiroidea aproximada, centro pélvico y región prostática aproximada.

Los resultados muestran que la base cervical y el centro pélvico son referencias útiles porque se obtienen a partir de puntos corporales relativamente estables: hombros y caderas. A partir de estos landmarks se calcularon las regiones anatómicas aproximadas de interés. En particular, la región tiroidea aproximada se obtuvo mediante una interpolación entre la base cervical y la nariz, mientras que la región prostática aproximada se calculó mediante un desplazamiento vertical desde el centro pélvico.

La principal ventaja de este enfoque es que permite obtener referencias anatómicas externas sin necesidad de entrenar un modelo específico para detectar tiroides o próstata. Esto resulta útil en una primera aproximación experimental, ya que se aprovecha la salida de un modelo de pose humana ya existente.

Sin embargo, los resultados también confirman una limitación importante: estos landmarks no representan órganos internos reales, sino referencias externas aproximadas. La tiroides y la próstata no son visibles mediante una cámara RGB, por lo que los puntos calculados deben interpretarse como zonas de referencia para posicionamiento robótico y no como localizaciones clínicas precisas.

Desde el punto de vista del objetivo del TFG, esta aproximación resulta suficiente, ya que la finalidad del sistema no es diagnosticar ni localizar órganos internos, sino situar el robot frente a zonas externas de interés para una posible medición radiológica posterior.

6.3 Resultados de la estimación de profundidad

La estimación de profundidad mediante Depth Anything 3 permitió asociar una señal de proximidad a los landmarks anatómicos calculados. El sistema pudo consultar el mapa de profundidad generado por el modelo en torno a puntos concretos, utilizando una ventana local para evitar depender de un único píxel.

Los resultados muestran que la profundidad estimada por Depth Anything 3 puede variar de forma coherente cuando la persona se encuentra a diferentes distancias respecto a la cámara. Esta propiedad permitió utilizar la salida del modelo como una señal relativa para clasificar la posición de la persona en estados funcionales: cerca, distancia adecuada o lejos.

No obstante, los experimentos también muestran que Depth Anything 3 no debe interpretarse directamente como un sensor métrico absoluto. Aunque el modelo genera valores numéricos de profundidad, estos valores no siempre coinciden con la distancia real medida. Por tanto, su uso más adecuado en este proyecto es como indicador relativo de proximidad.

El suavizado temporal resultó necesario para reducir las variaciones entre frames consecutivos. Sin este suavizado, pequeñas oscilaciones en la profundidad podían provocar cambios frecuentes en el estado de distancia y, por tanto, en la acción generada por el robot. La aplicación de una mediana temporal permitió obtener una señal más estable y adecuada para la lógica de decisión.

6.4 Resultados de la comparativa RealSense–Depth Anything 3

La comparación entre RealSense y Depth Anything 3 permitió valorar las diferencias entre una cámara RGB-D y un modelo de profundidad monocular. Como se mostró en la Tabla 5.3, RealSense obtuvo menores valores de MAE, RMSE y MAPE respecto a la distancia real medida, mientras que Depth Anything 3 presentó una señal temporalmente más estable en la comparativa global.

Los menores valores de error obtenidos por RealSense eran esperables, ya que este dispositivo dispone de un sensor físico de profundidad, mientras que Depth Anything 3 estima la profundidad a

partir de una única imagen RGB. Por tanto, desde el punto de vista estrictamente métrico, RealSense proporcionó una medida más próxima a la distancia real utilizada como referencia.

No obstante, estos mejores valores métricos no implican que la señal de RealSense fuera la más adecuada para la lógica final de movimiento. En el uso concreto del proyecto, la profundidad se consultaba en ventanas locales asociadas a landmarks anatómicos detectados en imagen. En esas condiciones, la señal podía presentar saltos entre fotogramas, valores no válidos o variaciones debidas a pequeñas imprecisiones del landmark, a discontinuidades del mapa de profundidad o a la geometría de la ropa y del cuerpo.

Por ello, la decisión de no utilizar RealSense como fuente final de profundidad no se debió a que sus valores fueran siempre incorrectos, sino a que su comportamiento local no resultaba suficientemente estable para gobernar directamente el movimiento del robot. Una variación puntual podía provocar cambios bruscos entre estados como *CERCA*, *BIEN_DISTANCIA* o *LEJOS*.

En cambio, Depth Anything 3 obtuvo valores competitivos en estabilidad temporal, con una desviación típica y una diferencia entre frames consecutivos inferiores en la comparativa global. Aunque su error métrico fue mayor, su salida resultó útil como señal relativa de proximidad al combinarse con suavizado temporal, umbrales experimentales y bloqueo de posición alcanzada.

La conclusión principal de esta comparativa es que Depth Anything 3 no sustituye directamente a una cámara RGB-D cuando se requiere precisión métrica. Sin embargo, sí puede resultar útil como señal relativa para una lógica de posicionamiento, especialmente cuando el objetivo no es medir una distancia física exacta, sino decidir si el robot debe acercarse, alejarse o detenerse.

6.5 Resultados del sistema de decisión

El sistema de decisión permitió transformar la información visual y de profundidad en acciones de movimiento. A partir de la profundidad suavizada, el sistema clasificó la situación de la persona como cerca, en rango adecuado o lejos. Además, mediante el error horizontal del landmark seleccionado, se evaluó si el robot estaba centrado respecto a la persona.

Los resultados muestran que la lógica de decisión funcionó de forma coherente en las pruebas realizadas. Cuando la persona se encontraba demasiado cerca, el sistema generaba la acción *ALEJAR*. Cuando se encontraba demasiado lejos, generaba la acción *ACERCAR*. Cuando la distancia era adecuada y el landmark estaba centrado, la acción generada era *PARAR*.

La incorporación de acciones combinadas permitió mejorar el comportamiento del sistema. En lugar de regular únicamente la distancia, el robot podía corregir también su alineación horizontal. Esto es relevante porque el objetivo del proyecto no es solo aproximarse a la persona, sino situarse frente a una región anatómica externa concreta.

Uno de los resultados más importantes fue la necesidad de incorporar un bloqueo de posición alcanzada. Sin este mecanismo, pequeñas oscilaciones de la señal de profundidad podían provocar cambios repetidos entre acciones. Con el bloqueo, el sistema mantiene la parada cuando alcanza una posición válida y solo vuelve a moverse si detecta un cambio significativo y persistente.

Por tanto, la lógica de decisión no se limitó a una clasificación instantánea, sino que incorporó mecanismos de estabilización necesarios para obtener un comportamiento más robusto.

6.6 Resultados del movimiento autónomo del robot

La integración con el MiniCERNBot permitió comprobar que las acciones generadas por el sistema podían transformarse en movimiento real. La arquitectura completa permitió conectar la percepción visual, la estimación de profundidad, la publicación en ROS2, la comunicación con Android y el envío de comandos por Bluetooth al robot.

Durante las pruebas, el robot fue capaz de ejecutar las acciones de posicionamiento previstas: avanzar, retroceder, detenerse y corregir lateralmente su posición. Estas acciones se generaron a

partir de la distancia relativa estimada y del centrado horizontal del landmark seleccionado, por lo que el movimiento del robot respondió directamente a la información visual obtenida por el sistema.

El resultado más relevante fue la validación de la cadena completa de percepción, decisión y actuación. El sistema pudo detectar landmarks anatómicos externos, estimar una señal de proximidad, generar una acción de movimiento y transmitirla hasta una plataforma robótica real.

Debe señalarse que el movimiento autónomo validado se corresponde con el alcance definido para este TFG: un posicionamiento básico frente a la persona mediante acciones discretas. Por tanto, el sistema no pretende resolver una navegación autónoma completa en entornos complejos, ni incluye planificación global de trayectorias. Sin embargo, dentro del objetivo planteado, el robot realizó correctamente las acciones necesarias para aproximarse, alejarse, detenerse o corregir su orientación relativa frente al paciente.

6.7 Grado de consecución de los objetivos

La Tabla 6.1 resume el grado de consecución de los objetivos específicos planteados al inicio del trabajo.

Tabla 6.1: Grado de consecución de los objetivos del TFG

Objetivo	Grado de consecución
Estudiar y seleccionar un modelo de estimación de pose humana adecuado.	Alcanzado
Implementar un sistema de detección de pose basado en RTM-Pose.	Alcanzado
Definir landmarks anatómicos externos a partir de keypoints corporales.	Alcanzado
Diferenciar entre referencias externas y localización clínica real de órganos internos.	Alcanzado
Incorporar validación de orientación frontal del paciente.	Alcanzado
Integrar Depth Anything 3 como señal de profundidad asociada a landmarks.	Alcanzado
Comparar Depth Anything 3 con RealSense mediante métricas experimentales.	Alcanzado
Diseñar una lógica de decisión basada en distancia y centrado horizontal.	Alcanzado
Publicar la información del sistema mediante ROS2.	Alcanzado
Implementar comunicación entre ROS2, Android y MiniCERNBot.	Alcanzado
Validar el movimiento autónomo del robot a partir de la percepción visual.	Alcanzado

El objetivo general del trabajo puede considerarse alcanzado, ya que se ha desarrollado una arquitectura funcional capaz de detectar landmarks anatómicos externos, estimar una señal de profundidad relativa y generar acciones de posicionamiento para un robot móvil. La validación con MiniCERNBot permitió comprobar que dichas acciones podían ejecutarse sobre una plataforma robótica real, completando la cadena de percepción, decisión y actuación.

No obstante, el alcance del movimiento autónomo debe interpretarse dentro de los límites definidos para este TFG. El sistema valida un posicionamiento básico frente a la persona mediante acciones discretas, pero no aborda navegación autónoma completa, planificación global de trayectorias ni validación en un entorno hospitalario real.

6.8 Limitaciones del sistema

A pesar de los resultados obtenidos, el sistema presenta varias limitaciones que deben tenerse en cuenta.

En primer lugar, los landmarks anatómicos calculados son aproximaciones externas. No representan la posición real de órganos internos y no pueden utilizarse como referencias clínicas exactas. Su utilidad se limita al posicionamiento robótico y a la delimitación aproximada de zonas externas de interés.

En segundo lugar, la estimación de profundidad mediante Depth Anything 3 no proporciona una distancia métrica exacta sin calibración. Aunque la señal puede utilizarse de forma relativa, su error respecto a la distancia real es mayor que el obtenido con RealSense. Esto limita su uso en aplicaciones que requieran precisión métrica estricta.

En tercer lugar, el sistema ha sido probado en condiciones experimentales controladas. En un entorno hospitalario real podrían aparecer factores que afecten al rendimiento: iluminación variable, presencia de otras personas, oclusiones, movimiento del paciente, ropa hospitalaria, limitaciones de espacio o restricciones de seguridad.

En cuarto lugar, la validación de orientación frontal depende de la detección de keypoints faciales y corporales. Si la cara está parcialmente oculta o el modelo detecta puntos faciales erróneos, la clasificación de frontalidad puede verse afectada.

En quinto lugar, el movimiento del robot se basa en acciones discretas y no en un controlador continuo de posición. Esto permite validar la arquitectura de percepción y decisión, pero no garantiza un posicionamiento óptimo en todos los escenarios.

Por último, el sistema no incluye todavía el módulo de medición radiológica. Por tanto, no se ha validado la utilidad clínica final de la arquitectura, sino únicamente la etapa previa de posicionamiento.

6.9 Discusión general

Los resultados obtenidos muestran que es posible construir una arquitectura robótica funcional a partir de la combinación de estimación de pose humana, landmarks anatómicos externos, profundidad monocular, ROS2 y comunicación con una plataforma móvil.

La principal aportación del trabajo no reside en desarrollar un nuevo modelo de visión artificial, sino en integrar herramientas existentes dentro de una cadena robótica completa. RTMPose proporciona la estructura corporal, el motor de landmarks adapta esa información a las necesidades del proyecto, Depth Anything 3 aporta una señal relativa de proximidad, ROS2 organiza la comunicación y Android permite transmitir las acciones al MiniCERNBot.

Uno de los aspectos más relevantes del proyecto es la diferenciación entre precisión clínica y utilidad robótica. El sistema no pretende localizar órganos internos, sino obtener referencias externas suficientemente coherentes para posicionar un robot. Esta diferencia es fundamental para interpretar correctamente el alcance del trabajo.

También resulta relevante la interpretación de Depth Anything 3. Los resultados muestran que no debe emplearse como una medida directa de distancia real sin calibración, pero sí puede ser útil como indicador relativo. Esta conclusión es importante porque permite aprovechar modelos monoculares de profundidad en tareas donde no se requiere una métrica exacta, sino una decisión funcional basada en proximidad.

Desde el punto de vista robótico, la integración con el MiniCERNBot demuestra que la percepción visual puede transformarse en movimiento real. Aunque el sistema todavía es experimental, valida una primera cadena de percepción, decisión y actuación que puede servir como base para desarrollos posteriores.

En conjunto, el proyecto cumple su objetivo principal: desarrollar una arquitectura inicial para que un robot móvil pueda situarse frente a una persona utilizando landmarks anatómicos externos y profundidad relativa. Las limitaciones observadas no invalidan el trabajo, sino que delimitan claramente su alcance y señalan las líneas de mejora necesarias para avanzar hacia una aplicación más robusta y cercana a un entorno hospitalario real.

7. Conclusiones y trabajo futuro

7.1 Conclusiones

En este Trabajo Final de Grado se ha desarrollado una arquitectura de percepción, decisión y actuación para el posicionamiento de un robot móvil frente a una persona. El sistema se plantea como una etapa previa a una posible aplicación asistencial en la que el robot pueda situarse de forma adecuada frente a regiones anatómicas externas de interés, como la zona tiroidea o la región prostática, antes de realizar futuras mediciones radiológicas localizadas.

El trabajo ha permitido integrar distintos módulos tecnológicos dentro de una misma cadena funcional. En primer lugar, se ha utilizado RTMPose para detectar la pose humana en imágenes RGB y obtener los keypoints corporales necesarios. A partir de estos puntos se han definido landmarks anatómicos externos aproximados, como la base cervical, la región tiroidea aproximada, el centro pélvico y la región prostática aproximada.

Uno de los aspectos más importantes del proyecto ha sido la diferenciación entre una referencia anatómica externa y una localización clínica real. Los landmarks calculados no representan la posición exacta de órganos internos, ya que una cámara RGB no permite observar directamente estructuras como la tiroides o la próstata. Sin embargo, estos puntos sí resultan útiles como referencias externas para orientar el posicionamiento del robot y delimitar zonas aproximadas de interés.

También se ha incorporado una validación de orientación frontal del paciente. Esta condición resulta necesaria porque la aplicación prevista asume que, en un entorno hospitalario, el paciente se colocaría de frente antes de realizar una medición localizada. Por tanto, el sistema solo permite utilizar la información anatómica y de profundidad cuando la postura observada es coherente con dicha situación.

Respecto a la estimación de profundidad, se ha integrado Depth Anything 3 como fuente de profundidad monocular. Las pruebas realizadas muestran que este modelo no debe interpretarse directamente como una medida métrica exacta sin calibración, pero sí puede utilizarse como una señal relativa de proximidad. Mediante la lectura de profundidad en ventanas locales, el suavizado temporal y el uso de umbrales experimentales, esta señal se ha transformado en estados funcionales como *CERCA*, *BIEN_DISTANCIA* y *LEJOS*.

La comparación con RealSense permitió comprobar que la cámara RGB-D ofrece mejores resultados desde el punto de vista métrico, especialmente en términos de MAE, RMSE y MAPE.

Finalmente, se ha validado la integración con el robot MiniCERNBot. La arquitectura implementada permite capturar imagen, detectar pose, calcular landmarks anatómicos, estimar profundidad, publicar información en ROS2, enviar acciones a una aplicación Android y transmitir comandos al robot mediante Bluetooth. Con ello, el sistema ha demostrado ser capaz de transformar información visual en acciones reales de posicionamiento, como acercarse, alejarse, detenerse o corregir lateralmente la posición.

En conjunto, el objetivo general del TFG puede considerarse alcanzado. Se ha desarrollado una primera arquitectura funcional de posicionamiento robótico basada en visión artificial, landmarks anatómicos externos y profundidad relativa. Aunque el sistema todavía requiere mejoras antes de poder aplicarse en un entorno hospitalario real, los resultados obtenidos constituyen una base sólida para continuar el desarrollo.

7.2 Aportaciones principales del proyecto

Las principales aportaciones del proyecto pueden resumirse en los siguientes puntos:

- Desarrollo de una arquitectura completa de percepción, decisión y actuación para posicionamiento robótico frente a una persona.
- Integración de RTMPose dentro de un sistema propio para la detección de pose humana en tiempo real.
- Definición de landmarks anatómicos externos aproximados a partir de keypoints corporales estándar.
- Incorporación de una validación de orientación frontal como condición previa para permitir la medición.
- Integración de Depth Anything 3 como fuente de profundidad monocular asociada a landmarks anatómicos.
- Comparación experimental entre la profundidad estimada por Depth Anything 3 y la profundidad proporcionada por RealSense.
- Interpretación de la profundidad monocular como señal relativa de proximidad, no como medida métrica exacta.
- Diseño de una lógica de decisión basada en distancia relativa, centrado horizontal y bloqueo de posición alcanzada.
- Publicación de información del sistema mediante ROS2 para facilitar la depuración, visualización y comunicación entre módulos.
- Implementación de una comunicación distribuida entre PC, ROS2, Android y MiniCERNBot.
- Validación del movimiento del robot a partir de las acciones generadas por el sistema de percepción.

Estas aportaciones muestran que el proyecto no se limita a probar un modelo de visión artificial de forma aislada, sino que desarrolla una cadena robótica completa. La información visual obtenida se procesa, se interpreta y se convierte en acciones ejecutables por una plataforma móvil real.

7.3 Limitaciones actuales

A pesar de los resultados obtenidos, el sistema presenta varias limitaciones que deben tenerse en cuenta.

La primera limitación está relacionada con la naturaleza aproximada de los landmarks anatómicos. Las referencias calculadas no corresponden a órganos internos reales, sino a puntos externos derivados geométricamente a partir de keypoints corporales. Esto limita su uso a tareas de posicionamiento y orientación, no a aplicaciones clínicas de localización anatómica precisa.

La segunda limitación se encuentra en la estimación de profundidad monocular. Depth Anything 3 proporciona una señal útil para distinguir situaciones relativas de cercanía o lejanía, pero no garantiza una distancia real exacta sin calibración adicional. Por tanto, el sistema no debe emplearse directamente en tareas que requieran precisión métrica estricta.

La tercera limitación corresponde al entorno de validación. Las pruebas se han realizado en condiciones experimentales controladas, no en un hospital real. En un entorno clínico podrían aparecer factores adicionales como iluminación variable, oclusiones, presencia de otras personas, ropa hospitalaria, restricciones de espacio o movimientos imprevistos del paciente.

Otra limitación importante está relacionada con la orientación del paciente. El sistema asume que la persona debe colocarse de frente al robot, lo cual es coherente con la aplicación prevista. Sin embargo, si la postura no es frontal o los keypoints faciales no se detectan correctamente, la medición se bloquea o puede perder fiabilidad.

Por último, también debe considerarse que el movimiento del robot se basa en acciones discretas. El sistema permite avanzar, retroceder, detenerse o corregir lateralmente la posición, pero no implementa un controlador continuo de posición ni una navegación autónoma completa en entornos complejos.

7.4 Líneas de trabajo futuro

A partir de las limitaciones observadas, se proponen varias líneas de trabajo futuro orientadas a mejorar la robustez, precisión e integración del sistema.

7.4.1 Calibración de la profundidad monocular

Una primera línea de mejora consiste en calibrar la salida de Depth Anything 3 para aproximarla mejor a distancias reales. En este TFG, la profundidad monocular se ha utilizado como una señal relativa de proximidad, pero no como una medida métrica exacta.

En trabajos futuros podría realizarse una calibración experimental comparando la salida del modelo con distancias reales medidas en diferentes condiciones. Esto permitiría ajustar funciones de conversión o corrección para transformar la profundidad estimada en una medida más próxima a la distancia física.

También podría estudiarse una calibración específica por landmark, ya que la profundidad estimada puede comportarse de forma distinta en la zona cervical, pélvica o en otras regiones del cuerpo. Esta mejora permitiría utilizar la profundidad monocular con mayor precisión dentro de la lógica de posicionamiento del robot.

7.4.2 Mejora de la robustez ante oclusiones

Otra línea de trabajo importante es mejorar la robustez del sistema ante oclusiones y detecciones incompletas. En escenarios reales, algunos keypoints pueden no ser visibles debido a la postura del paciente, la ropa, la posición de la cámara o la presencia de objetos.

Para abordar este problema, podrían incorporarse estrategias de seguimiento temporal de keypoints, filtros predictivos o modelos capaces de estimar landmarks aunque parte del cuerpo esté

parcialmente oculto. También sería útil implementar una lógica de recuperación que mantenga temporalmente una estimación válida cuando se pierda un landmark durante pocos frames.

Esta mejora permitiría reducir interrupciones en la medición y aumentar la estabilidad del sistema en situaciones menos controladas.

7.4.3 Entrenamiento o ajuste con imágenes hospitalarias

El sistema se ha validado en un entorno experimental, pero su futura aplicación en contextos médicos requeriría pruebas con imágenes más representativas del entorno hospitalario. La ropa del paciente, las posturas habituales, la iluminación y el mobiliario pueden afectar al rendimiento de los modelos de visión artificial.

Por ello, una línea futura sería recopilar o utilizar un conjunto de imágenes representativas de pacientes en condiciones similares a las de la aplicación prevista. Con este material podría evaluarse la robustez de RTMPose y de los landmarks definidos, o incluso ajustar modelos específicos para mejorar la detección en este tipo de escenarios.

También podría estudiarse la incorporación de reglas específicas para ropa hospitalaria, batas u oclusiones frecuentes, con el objetivo de hacer el sistema más fiable en condiciones reales.

7.4.4 Integración completa en una plataforma robótica autónoma

Aunque el sistema desarrollado permite validar la cadena de percepción, decisión y actuación, la integración robótica todavía puede ampliarse. En este TFG, el movimiento se ha basado en acciones discretas enviadas al MiniCERNBot mediante Android y Bluetooth.

En trabajos futuros sería conveniente integrar el sistema dentro de una plataforma robótica autónoma más completa, con control continuo de movimiento, navegación local, evitación de obstáculos y planificación de trayectorias. Esto permitiría que el robot no solo corrigiera su posición frente a una persona, sino que también pudiera desplazarse de forma autónoma en un entorno más amplio.

Además, podría sustituirse la comunicación intermedia mediante Android por una integración directa con ROS2 en la propia plataforma robótica, reduciendo la complejidad de la arquitectura distribuida y mejorando la respuesta del sistema.

7.4.5 Validación en escenarios más realistas

Finalmente, una línea de trabajo esencial sería validar el sistema en escenarios más próximos a la aplicación final. Esto incluiría pruebas con diferentes personas, distintas complexiones, variaciones de altura, ropa hospitalaria, cambios de iluminación y presencia de elementos que puedan producir oclusiones.

También sería necesario evaluar el comportamiento del robot en espacios reducidos y con restricciones de seguridad. En un entorno real, el robot debe moverse de forma controlada, predecible y segura, especialmente si trabaja cerca de pacientes o personal sanitario.

Esta validación permitiría comprobar si la arquitectura desarrollada mantiene su funcionamiento fuera del entorno experimental inicial y qué ajustes serían necesarios antes de plantear una futura aplicación hospitalaria.

En definitiva, el trabajo realizado constituye una primera base funcional sobre la que pueden desarrollarse mejoras posteriores. La integración de pose humana, landmarks anatómicos externos, profundidad relativa y movimiento robótico abre una línea de trabajo interesante para sistemas asistenciales que requieran posicionarse frente a regiones corporales concretas de forma autónoma y controlada.

A. Material complementario del proyecto

A.1 Repositorio y estructura de archivos del proyecto

El código fuente completo, los scripts auxiliares, los ficheros de configuración, las capturas adicionales y los resultados experimentales completos se han organizado en una carpeta externa de material complementario. En el cuerpo principal de esta memoria se ha incluido la información necesaria para comprender el diseño, la implementación y la validación del sistema, mientras que en este apéndice se recoge únicamente la información esencial para reproducir la ejecución principal.

La estructura del material complementario es la siguiente:

```
proyecto_tfg/  
|-- README.md  
|-- scripts_principales/  
|   |-- depth_da3_server.py  
|   |-- realsense_pose_server.py  
|   |-- landmarks_unified.py  
|   |-- publish_mobile_pose_topics.py  
|   '-- ros2_to_android_bridge.py  
|-- scripts_experimentacion/  
|-- resultados/  
|-- entornos/  
'-- videos/  
    |-- demo_movimiento_robot.mp4  
    '-- perspectiva_robot_datos.mp4
```

Los scripts principales corresponden a la arquitectura final del sistema. Los scripts de experimentación se utilizaron para pruebas offline, comparación de profundidad, análisis de resultados y generación de métricas. La carpeta de resultados contiene los ficheros CSV obtenidos durante la validación.

A.2 Comandos básicos de ejecución

La ejecución del sistema se realiza en varios terminales debido a la separación de entornos entre Depth Anything 3, OpenMMLab y ROS2 Humble. De forma general, el orden de ejecución es el siguiente:

```
# Terminal 1: servidor local de Depth Anything 3
conda activate depth3

python depth_da3_server.py \
  --host 127.0.0.1 \
  --port 8765 \
  --model depth-anything/DA3Metric-Large \
  --device cuda

# Terminal 2: sistema principal con RealSense, RTMPose y decisión
conda activate openmmlab

python realsense_pose_server.py

# Terminal 3: publicación de datos en ROS2
conda deactivate

source /opt/ros/humble/setup.bash
export ROS_LOCALHOST_ONLY=1
export ROS_DOMAIN_ID=42

/usr/bin/python3 publish_mobile_pose_topics.py

# Terminal 4: puente ROS2--Android
conda deactivate

source /opt/ros/humble/setup.bash
export ROS_LOCALHOST_ONLY=1
export ROS_DOMAIN_ID=42

/usr/bin/python3 ros2_to_android_bridge.py
```

Esta división permite ejecutar cada módulo en el entorno adecuado y evita conflictos entre dependencias. Depth Anything 3 se mantiene en su propio entorno, RTMPose se ejecuta en el entorno de OpenMMLab y los nodos ROS2 se lanzan desde el entorno del sistema.

A.3 Topics ROS2 publicados

Los principales topics publicados durante la ejecución del sistema fueron:

```
/pose_app/image/compressed
/pose_app/thyroid
/pose_app/prostate
/pose_app/keypoints
```

```
/pose_app/all_landmarks
/pose_app/orientation
/pose_app/measurement_allowed
/pose_app/debug
/pose_app/distance/raw_depth
/pose_app/distance/smooth_depth
/pose_app/distance/instant_state
/pose_app/distance/state
/pose_app/distance/action
/pose_app/distance/target
/pose_app/distance/target_name
/pose_app/distance/measurement_allowed
```

El topic más relevante para el movimiento del robot es */pose_app/distance/action*, ya que contiene la acción final generada por la lógica de decisión. Esta acción es recibida por el puente ROS2–Android y enviada posteriormente a la aplicación móvil para su transmisión al MiniCERN-Bot.

A.4 Material complementario

Debido a la extensión del código fuente y de los resultados experimentales completos, se ha optado por incluir dicho material en una carpeta externa de apoyo. Esta carpeta contiene los scripts principales, los scripts auxiliares utilizados durante la experimentación, los resultados almacenados en formato CSV, los archivos de configuración de los entornos y un fichero *README.md* con instrucciones de ejecución.

El material complementario puede consultarse en la siguiente **carpeta externa de material complementario**¹.

El fichero *README.md* incluido en la carpeta describe la función de cada script, los entornos necesarios, el orden de ejecución de los distintos módulos y la organización de los resultados experimentales.

La carpeta externa incluye también una subcarpeta denominada *entornos*, en la que se recogen los archivos *environment_depth3.yml* y *environment_openmmlab.yml*. Estos archivos permiten reconstruir los entornos de Conda utilizados para Depth Anything 3 y OpenMMLab/RTMPose. En el caso de ROS2 Humble, se incluye un fichero de notas con las variables de entorno y los comandos empleados, ya que los nodos de ROS2 se ejecutaron mediante el intérprete de Python del sistema.

A.5 Demostración en vídeo del sistema

Como parte del material complementario, se incluyen dos vídeos demostrativos del funcionamiento del sistema desarrollado. Estos vídeos permiten observar de forma directa la integración entre la percepción visual, la lógica de decisión, la comunicación entre dispositivos y el movimiento del robot MiniCERNBot.

El primer vídeo presenta una demostración general de la arquitectura completa. En él puede observarse cómo el robot se mueve de forma autónoma en función de la posición relativa de la persona. El sistema estima la distancia, evalúa el centrado horizontal y genera acciones de acercamiento, alejamiento, parada y corrección lateral.

La generación de acciones únicamente se habilita cuando la orientación de la persona se valida como frontal y se dispone de landmarks y valores de profundidad considerados fiables. Cuando la

¹https://drive.google.com/drive/folders/1ofm7XQByVwtwYFp3-z8pua8xAuqWYnGu?usp=drive_link

orientación no es válida, se pierde la detección de los landmarks o no se dispone de una medición adecuada, el sistema genera la acción *PARAR* como medida de seguridad.

La demostración general puede consultarse mediante el siguiente enlace:

Vídeo 1: demostración del movimiento autónomo del MiniCERNBot

El segundo vídeo muestra la perspectiva del sistema de percepción, es decir, la información procesada desde el punto de vista de la cámara instalada en el robot. Sobre la imagen se representan el esqueleto corporal detectado mediante RTMPose, los landmarks anatómicos externos, la orientación estimada de la persona, la profundidad obtenida mediante Depth Anything 3, el estado de distancia y la acción final generada por la lógica de decisión.

Este vídeo permite relacionar la información interpretada por el sistema con el comportamiento observado en el robot y puede consultarse mediante el siguiente enlace:

Vídeo 2: visualización de la percepción y de los datos generados por el sistema

Ambos vídeos se encuentran también incluidos en la carpeta externa de material complementario. Su finalidad es complementar la descripción experimental y los resultados recogidos en la memoria, facilitando la comprensión del funcionamiento dinámico de la arquitectura desarrollada.

Bibliografía

- ByteDance-Seed. (2026). *Depth Anything 3*. Consultado el 20 de mayo de 2026, desde <https://github.com/ByteDance-Seed/Depth-Anything-3>
- Cao, Z., Hidalgo, G., Simon, T., Wei, S.-E., & Sheikh, Y. (2021). OpenPose: Realtime Multi-Person 2D Pose Estimation Using Part Affinity Fields. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 43(1), 172-186. <https://doi.org/10.1109/TPAMI.2019.2929257>
- Intel. (2026). *Intel RealSense Depth Camera D435i Specifications*. Consultado el 20 de mayo de 2026, desde <https://www.intel.com/content/www/us/en/products/sku/190004/intel-realsense-depth-camera-d435i/specifications.html>
- Jiang, T., Lu, P., Zhang, L., Ma, N., Han, R., Lyu, C., Li, Y., & Chen, K. (2023). RTMPose: Real-Time Multi-Person Pose Estimation Based on MMPose. <https://doi.org/10.48550/arXiv.2303.07399>
- Marzà, D. (2026). *cirtesu_da3_mapping* [Repositorio utilizado como apoyo para la integración de Depth Anything 3 y ROS2]. Consultado el 20 de mayo de 2026, desde https://github.com/diegomarzaa/cirtesu_da3_mapping
- Morgan, A. A., Abdi, J., Syed, M. A. Q., Kohen, G. E., Barlow, P., & Vizcaychipi, M. P. (2022). Robots in Healthcare: A Scoping Review. *Current Robotics Reports*, 3(4), 271-280. <https://doi.org/10.1007/s43154-022-00095-4>
- Open Robotics. (2026a). *ROS 2 Documentation: Basic Concepts*. Consultado el 20 de mayo de 2026, desde <https://docs.ros.org/en/humble/Concepts/Basic.html>
- Open Robotics. (2026b). *ROS 2 Documentation: Nodes*. Consultado el 20 de mayo de 2026, desde <https://docs.ros.org/en/humble/Concepts/Basic/About-Nodes.html>
- OpenMMLab. (2026). *MMPose: OpenMMLab Pose Estimation Toolbox*. Consultado el 20 de mayo de 2026, desde <https://github.com/open-mmlab/mmpose>
- PcComponentes. (2026a). *Móviles Android*. Consultado el 20 de mayo de 2026, desde <https://www.pccomponentes.com/smartphone-moviles/moviles-android>
- PcComponentes. (2026b). *Portátiles con NVIDIA GeForce RTX 4060*. Consultado el 20 de mayo de 2026, desde <https://www.pccomponentes.com/portatiles/geforce-rtx-4060>

- RealSense. (2026). *RealSense Depth Camera D435i*. Consultado el 20 de mayo de 2026, desde <https://store.realsenseai.com/buy-intel-realsense-depth-camera-d435i.html>
- Ultralytics. (2026). *Pose Estimation*. Consultado el 20 de mayo de 2026, desde <https://docs.ultralytics.com/tasks/pose/>
- Xu, Y., Zhang, J., Zhang, Q., & Tao, D. (2022). ViTPose: Simple Vision Transformer Baselines for Human Pose Estimation. *Advances in Neural Information Processing Systems*, 35, 38571-38584. https://proceedings.neurips.cc/paper_files/paper/2022/hash/fbb10d319d44f8c3b4720873e4177c65-Abstract-Conference.html
- Zheng, C., Wu, W., Chen, C., Yang, T., Zhu, S., Shen, J., Kehtarnavaz, N., & Shah, M. (2023). Deep Learning-Based Human Pose Estimation: A Survey. *ACM Computing Surveys*, 56(1), 1-37. <https://doi.org/10.1145/3603618>